

INFORME SEGUNDA ENTREGA: CLUSTERIZACIÓN

Aprendizaje No Supervisado con K-Means sobre Secondary Mushroom Dataset

Materia: Ciencia de Datos	Entrega: 2da Entrega - Agrupamiento No Supervisado	Muestras: 60.923 Variables: 13
---------------------------	--	----------------------------------

Introducción: Contexto y Objetivo del Proyecto

El presente proyecto de la materia **Ciencia de Datos** aborda el análisis sistemático y la minería de conocimiento sobre el **Secondary Mushroom Dataset**, una base de datos masiva con más de 61.000 observaciones de hongos y 21 atributos descriptivos, diseñada a partir de compendios taxonómicos de micología botánica.

Propósito de la Segunda Entrega: En esta etapa, el requerimiento principal consiste en desarrollar un modelo de **aprendizaje no supervisado mediante algoritmos de clusterización (K-Means)** para particionar los especímenes en conglomerados naturales según sus **propiedades morfológicas** (estructuras anatómicas de sombrero, estípite, láminas y anillo). El propósito es descubrir fenotipos homogéneos sin recurrir a la etiqueta de toxicidad (*class: edible/poisonous*), emulando la tarea taxonómica real de catalogación morfológica y analizando en profundidad cómo se agrupan los hongos en el espacio multidimensional.

Pasos Metodológicos Seguidos para Lograr la Clusterización:

Para transformar la base de datos cruda y ruidosa en un agrupamiento consistente, validado e interpretable, se ejecutó un pipeline estructurado en 6 fases consecutivas:

Fase / Paso	Descripción de la Tarea Ejecutada	Resultado / Salida Técnica
Paso 1: Auditoría y Limpieza Primaria	Inspección de calidad, cuantificación de valores faltantes por atributo y detección de duplicados exactos generados en la digitalización.	Eliminación de 146 filas duplicadas (base de 60.923 registros). Diagnóstico de 4 columnas críticas con >70% de nulos.
Paso 2: Filtrado Dimensional Morfológico	Aislamiento estricto de variables físicas corporales del hongo. Descarte de la variable supervisada <i>class</i> y factores ecológicos externos (hábitat/estación).	Selección de 13 atributos puramente morfológicos de sombrero, pie, láminas y anillo. Eliminación de 4 columnas con vacío de datos.
Paso 3: Imputación Estadística de Nulos	Resolución del vacío informativo aplicando estimadores robustos: mediana para dimensiones métricas y moda para categorías anatómicas.	Matriz 100% densa (0 valores faltantes) preservando el 99.76% del volumen muestral sin distorsión de outliers.
Paso 4: Estandarización y Codificación Vectorial	Construcción de un espacio geométrico apto para distancias euclídeas mediante StandardScaler en numéricas y OneHotEncoder en nominales.	Espacio euclídeo ortogonal continuo donde cada dimensión aporta de forma equitativa sin sesgo de escalas métricas.
Paso 5: Modelado No Supervisado y Validación (K-Means)	Entrenamiento de modelos con inicialización k-means++ comparando K=5 y K=6. Proyección PCA 2D y evaluación con Silhouette y Davies-Bouldin.	Elección de K=6 por mejor separación de grupos (Davies-Bouldin = 0.8425) y mayor resolución anatómica.
Paso 6: Caracterización y Perfilado Biológico	Extracción de centroides, perfiles modales y frecuencias relativas de cada cluster para asignarles nombres descriptivos y diagnósticos morfológicos.	Identificación de 6 morfotipos distintivos (anillados, boletales gruesos, gráciles pequeños, singulares gigantes, etc.).

Hoja de Ruta del Informe: A continuación se detallan exhaustivamente los 4 ejes requeridos para esta entrega: **(1)** Cambios entre datasets, **(2)** Tratamiento de nulos, **(3)** Funcionamiento de K-Means y selección de K, y **(4)** Caracterización y denominación de los clusters resultantes.

1. Cambios entre el Dataset Original y el Actual

Para lograr una clusterización fenotípica interpretable y robusta, el dataset **Secondary Mushroom** fue sometido a un proceso de curación enfocado en la anatomía estructural del hongo, eliminando sesgos supervisados, redundancias y dimensiones sin soporte informacional.

Aspecto	Dataset Original	Dataset Actual (Modelado)	Impacto y Justificación Técnica
Registros (Filas)	61,069 filas	60,923 filas limpias	Se identificaron y eliminaron 146 registros duplicados exactos. Esto previene un sobre peso espurio en el cálculo de centroides euclídeos.
Dimensiones (Columnas)	21 variables mixtas	13 variables morfológicas	Se acotó el análisis a los atributos físicos medibles del espécimen (sombrero, estípite, láminas y anillo), garantizando homogeneidad semántica.
Variable Objetivo (class)	Presente (e: edible / p: poisonous)	Excluida del pipeline	El objetivo de esta entrega es la clusterización no supervisada . Mantener la etiqueta de toxicidad sesgaría la formación natural de grupos anatómicos.
Atributos con >70% Nulos	4 columnas casi vacías (72-84% NaN)	Eliminadas por completo	Las columnas <i>stem-root</i> , <i>veil-type</i> , <i>veil-color</i> y <i>spore-print-color</i> carecían de masa crítica de datos, haciendo su imputación contraproducente.
Variables de Contexto	habitat, season (ecológicas)	Removidas	Variables estacionales y ecológicas externas fueron descartadas para aislar exclusivamente la morfología corporal intrínseca de los hongos.


Estructura Anatómica de las 13 Variables Morfológicas Conservadas:

- **Sombrero (Pileus):** cap-diameter (numérico continuo en cm, media: 6.7 cm), cap-shape (forma: cónica, convexa, plana, etc.), cap-surface (textura: lisa, fibrosa, viscosa), cap-color (tonalidad cromática dominante).
- **Pie / Estípite (Stipe):** stem-height (longitud en cm), stem-width (grosor basal en mm), stem-color (color), stem-surface (textura superficial).
- **Láminas / Himenio (Gills):** gill-color (coloración del himenio), gill-attachment (tipo de inserción al pie: adnatas, libres, poroides, decurrentes), gill-spacing (densidad: cerrado vs distante).
- **Anillo / Velo (Annulus):** has-ring (indicador binario t/f de presencia de anillo), ring-type (tipología estructural del anillo: colgante, evanescente, membranoso, etc.).

Resumen Cuantitativo: El dataset pasó de una matriz cruda de **61.069 filas × 21 columnas** con 33% de valores faltantes agregados y variable supervisada, a una matriz morfológica optimizada de **60.923 filas × 13 columnas** 100% completas y estandarizadas.

2. Tratamiento de Datos Nulos

Los valores faltantes en el Secondary Mushroom Dataset no ocurren de forma aleatoria, sino que siguen patrones estructurales ligados a familias micológicas (por ejemplo, especies que carecen por completo de velo o pie). Se aplicó una metodología sistemática de dos etapas: **descarte dimensional con umbral técnico del 70%** e **imputación estadística diferenciada por escala métrica**.



Categoría de Atributo	Variables Afectadas	% Nulos	Tratamiento Aplicado	Fundamento Estadístico y Micológico
Nulos Críticos (>70%)	stem-root (84.8%) veil-type (94.8%) veil-color (87.9%) spore-print-color (73.0%)	73% a 95%	Eliminación Completa de la Columna	Imputar más del 70% de las observaciones implicaría inventar artificialmente la mayor parte de la distribución, generando artefactos y distorsión en la métrica euclídea.
Variables Numéricas (<2%)	cap-diameter (0%) stem-height (0%) stem-width (1.7%)	0% a 1.7%	Imputación por Mediana	La mediana es un estimador de posición no paramétrico insensible a la asimetría de la muestra y valores extremos (hongos gigantes atípicos), preservando el centroide biológico real.
Variables Categóricas (<20%)	cap-surface (18.3%) stem-surface (15.8%) gill-attachment (16.2%) gill-spacing (1.4%)	1% a 19%	Imputación por Moda (Categoría Frecuente)	Reemplaza la ausencia por el fenotipo dominante de la población sin introducir categorías espurias ni alterar la cardinalidad del espacio categórico one-hot.


Evaluación de Alternativas de Limpieza Descartadas:

- Eliminación de Filas con Algún Nulo (Dropna):** Si se hubiesen eliminado todas las filas que contenían al menos un valor faltante, se hubiera descartado más del **82% de las muestras**, reduciendo la base de 61.069 a menos de 11.000 hongos y eliminando géneros enteros.
- Imputación por un Valor Fijo '0' o 'Desconocido' en Categóricas:** Introducir un valor neutro crea un 'cluster artificial de ceros' donde el algoritmo agrupa ejemplares simplemente porque compartían datos faltantes, y no por su afinidad morfológica real.
- Imputación por Media en Numéricas:** Descartada debido a que variables como stem-width presentan sesgo a la derecha con máximos extremos que inflarían erróneamente el valor representativo.

Resultado del Tratamiento de Nulos: Matriz 100% densa (cero valores nulos residuales) que retiene el **99.76% del volumen original** de hongos, apta para cálculo vectorial estricto.

3. Algoritmo K-Means: Concepto, Funcionamiento y Validación

K-Means es un algoritmo de aprendizaje no supervisado de particionamiento espacial. Busca particionar N observaciones en K clusters, asignando cada hongo al cluster con el **centroide (vector medio)** más próximo, optimizando la función de coste de inercia intra-cluster (*Within-Cluster Sum of Squares, WCSS*):



Ciclo Algorítmico Paso a Paso:


- **Paso 1: Inicialización Inteligente (k-means++)**: Se seleccionan K semillas iniciales de forma probabilística ponderada por distancia, garantizando que los centros iniciales queden bien separados y minimizando el riesgo de estancamiento en mínimos locales subóptimos.
- **Paso 2: Asignación a Centroides Cercanos**: Cada hongo x_i calcula su distancia euclídea a los K centros actuales y se asigna al más cercano: $C(i) = \operatorname{argmin}_k \|x_i - \mu_k\|^2$.
- **Paso 3: Actualización y Recálculo**: Cada centroide μ_k se reubica en la posición media exacta de todos los datos pertenecientes a dicho grupo: $\mu_k = (1/|S_k|) \sum_{x \in S_k} x$.
- **Paso 4: Convergencia**: Se repiten los pasos 2 y 3 hasta que el desplazamiento de centroides sea inferior al umbral de convergencia ($\text{tol}=1e-4$) o se cumplan 500 iteraciones.

Preprocesamiento y Reducción Dimensional PCA:

- K-Means requiere un espacio métrico continuo euclídeo. Para procesar el dataset mixto se aplicó un pipeline de dos etapas:
1. **StandardScaler**: Estandarizó las variables métricas continuas (media 0, desviación 1), evitando que variables en milímetros dominen sobre variables en centímetros.
 2. **OneHotEncoder**: Codificó las variables nominales en variables binarias ortogonales (0/1), permitiendo comparaciones de distancia sin introducir relaciones ordinales falsas.
 3. **PCA (Componentes Principales)**: Para la visualización e inspección de fronteras se proyectó a 2 componentes principales (**PC1: 23.2%**, **PC2: 9.6%**, acumulando **32.9%** de varianza total).


Selección Experimental del Número de Clusters: K=5 vs K=6:

Métrica Intrínseca de Evaluación	Modelo K=5	Modelo K=6 (Seleccionado)	Análisis Comparativo y Decisión
Silhouette Score [-1 a +1, mayor = mejor]	0.3426	0.3284	Evalúa qué tan cohesionado está un punto con su cluster versus los vecinos. Ambos modelos muestran una excelente separación estructural (>0.32).
Davies-Bouldin Index ≥ 0 , menor = mejor]	0.8722	0.8425 (Óptimo)	Mide la similitud entre cada cluster y su vecino más parecido. K=6 reduce el índice a 0.8425 , lo que demuestra clusters con menor dispersión y mayor nitidez.
Resolución Morfológica	Mezcla hongos de gran porte con boletos	Aísla morfotipos puros y variantes raras	K=6 logra separar con éxito los hongos esféricos gigantes (Cluster 4) y diferencia los hongos de pie alto (Cluster 5) de los hongos robustos porosos (Cluster 1).



4. Caracterización Detallada de los Clusters (Modelo K=6)

A partir de las 60.923 muestras analizadas, el modelo K=6 descubrió 6 grupos fenotípicos bien diferenciados. A cada conglomerado se le asignó un nombre taxonómico descriptivo basado en sus variables dominantes:



Cluster / Nombre	Frecuencia	Dimensiones Promedio	Presencia Anillo	Morfología Diagnóstica
● Cluster 0 Anillados convexos marrones	9,221 (15.1%)	Sombrero: 6.0 cm Pie alto: 6.8 cm Pie ancho: 10.1 mm	100.0% con anillo ('t')	Espécimen arquetípico con anillo permanente. Sombrero convexo (forma 'x') de color marrón/castaño ('n') o amarillento ('y'). Láminas adnatas cerradas y pie cilíndrico blanquecino.
● Cluster 1 Grandes de poros (Morfología Boletoides)	4,957 (8.1%)	Sombrero: 13.6 cm Pie alto: 9.4 cm Pie ancho: 34.3 mm (Muy grueso)	0.1% con anillo	Hongos de textura masiva y estípite sumamente engrosado (~34.3 mm). Himenio poroide o decurrente (gill-attachment='p'). Carecen de anillo, sombrero ancho marrón oscuro o blanco.
● Cluster 2 Pegajosos sin anillo (Morfología Media)	19,642 (32.2%)	Sombrero: 7.7 cm Pie alto: 6.2 cm Pie ancho: 14.9 mm	7.7% con anillo	Segundo grupo en volumen (32.2%). Porte intermedio con cutícula lisa o pegajosa/viscosa (cap-surface='t'). Láminas decurrentes o adnatas, tonos castaños y pie desnudo sin estructuras anulares.
● Cluster 3 Pequeños sin anillo (Micenas y Gráciles)	21,964 (36.1%)	Sombrero: 3.0 cm Pie alto: 4.7 cm Pie ancho: 4.5 mm (Muy delgado)	3.2% con anillo	El cluster más numeroso (36.1%). Hongos pequeños y delicados de estípite delgado (~4.5 mm) y sombrero diminuto (~3 cm). Láminas adnatas y apretadas. Especímenes gregarios de hojarasca.
● Cluster 4 Esféricos gigantes amarillos (Singularidad / Raros)	353 (0.6%)	Sombrero: 50.3 cm (Gigante) Pie alto: 6.5 cm Pie ancho: 35.1 mm	0.0% con anillo	Cluster altamente singular (0.6%). Sombrero esférico monumental (cap-shape='o', 100%) amarillo brillante ('y', 100%) de medio metro de diámetro, con poros. Compatible con bejines gigantes (Calvatia).
● Cluster 5 Grandes blancos de pie alto (Porte Esbelto)	4,786 (7.9%)	Sombrero: 10.7 cm Pie alto: 13.9 cm (Muy alto) Pie ancho: 15.8 mm	78.0% con anillo	Hongos estilizados de notable altura (estípite de casi 14 cm). Sombrero amplio predominantemente blanco o claro con escamas. Elevada frecuencia de anillo (78%) y láminas libres/emarginadas.

Síntesis de Entrega: La clusterización mediante K-Means particionó exitosamente la diversidad de las 60.923 muestras en 6 morfotipos consistentes con la literatura biológica. Las variables más determinantes para la separación fueron el **tamaño relativo (cap-diameter, stem-width)**, la **presencia/ausencia de anillo (has-ring)** y el **tipo de inserción himenial (gill-attachment)**, logrando un agrupamiento cohesivo y no supervisado.