

CIENCIA DE DATOS



UNIDAD 2: EXTRACCIÓN-TRANSFORMACIÓN-CARGA

Mgtr. Ing. Mariano Martín Gualpa

FUENTES DE DATOS


Fuentes de Datos

- Puede ser el sitio original donde se crean los datos o donde se digitaliza por primera vez la información física.
- Pueden ser (entre otras):
 - base de datos
 - archivo plano
 - mediciones en tiempo real
 - datos en línea extraídos
 - datos estáticos o de transmisión disponibles en internet.
- Se clasifican en primarias y secundarias.

Fuentes de Datos

Existen diferentes clasificaciones para las fuentes de datos.

- Según su Procedencia Institucional.
- Según su Temporalidad.
- Según su Estructura.
- Según otros criterios.



Clasificaciones de fuentes de datos.



Según su Procedencia Institucional:

- Fuentes de Datos Internos:
 - Generados dentro de la organización.
 - Alta calidad y control.
 - Fuente principal para BI y predicciones operativas.
- Fuentes de Datos Externos:
 - Proviene desde afuera de la organización.
 - Permiten **enriquecer** modelos y para ciencia de datos predictiva y descriptiva.
 - Se incluye externos públicos, adquiridos y de socios.

Clasificaciones de fuentes de datos.

Según su Temporalidad:

- Datos Batch (históricos):
 - Procesados en bloques en momentos específicos.
 - Utilizados en data lakes y data warehouses.
- Datos en streaming (tiempo real):
 - Generados y procesados al instante.
 - Relevantes en arquitecturas event-driven y real-time analytics.



Clasificaciones de fuentes de datos.

Según su estructura:



- Datos estructurados:
 - Organizados en tablas (filas y columnas)
 - Muy utilizados en BI, modelos de Ciencia de Datos en general.
- Datos semiestructurados:
 - Formato flexible (JSON, XML, YAML, logs, etc).
 - Muy utilizados en integración de sistemas, APIs, y streaming.
- Datos no estructurados
 - Tienen una estructura interna, pero no están predefinidos mediante un modelo de datos.
 - Texto plano, imágenes, video, audio, etc.



```
{  
  "marcadores": [  
    {  
      "latitude": 40.416875,  
      "longitude": -3.703308,  
    },  
    {  
      "latitude": 40.417438,  
      "longitude": -3.693363,  
      "description": "Paseo del Prado"  
    },  
    {  
      "latitude": 40.407015,  
      "longitude": -3.691163,  
      "city": "Madrid",  
      "description": "Estación de Atocha"  
    }  
  ]  
}
```



Fuentes de Datos Típicas

- Bases de Datos:
 - Relacionales
 - NoSql
- APIs (Application Programming Interfaces):
 - Datos en texto sin formato
 - XML
 - HTML
 - JSON
 - Multimedia
- Web Scraping
- Data Streams

Algunos Repositorios de Datos Públicos

- CONICET: repositorio con producción de actividades científicas de los investigadores. Contiene artículos y otros resultados. Link: <https://ri.conicet.gov.ar/>
- Datos Argentina: datos públicos nacionales. Link: <https://datos.gob.ar/>
- NASA: centraliza datos abiertos geospaciales con más de 40.000 conjuntos de datos. Link: <https://data.nasa.gov/>
- Copernicus: programa de observación de la Tierra de la Unión Europea. Link: <https://www.copernicus.eu/es/acceso-los-datos/plataformas-convencionales-de-acceso-los-datos>
- Climate Data Online: agencia del gobierno norteamericana con datos meteorológicos y climáticos históricos a nivel mundial. Link: <https://www.ncdc.noaa.gov/cdo-web/>
- Registry of Research Data Repositories: Herramienta con catálogo de información sobre repositorios internacionales existentes de datos para investigadores. Link: <https://www.re3data.org/>
- Kaggle: plataforma web de comunidad Data Science, con recursos y competencias. Link: <https://www.kaggle.com/datasets/>
- Banco Mundial: datos sobre el desarrollo en el mundo. Link: <https://datos.bancomundial.org/>




EXTRACCIÓN-TRANSFORMACIÓN-CARGA

¿Que es ETL?


- Significa Extracción-Transformación-Carga (Extract-Transform-Load).
- Proceso de integración de datos que combina datos de múltiples fuentes en un almacén de datos único y consistente.
- Existe también el ELT.

Procesos ETL

ETL PROCESS



ELT PROCESS



Extracción-Transformación-Carga

- Los datos sin procesar se copian o exportan desde las ubicaciones origen al área de preparación.
- Múltiples fuentes de datos, estructurados y no estructurados.
- Ejemplos:
 - Servidores de Relacionales y NoSQL.
 - Sistemas CRM y ERP.
 - Archivos planos.
 - Correo electrónico.
 - Páginas web.
 - Multimedia (audios, imágenes, videos, etc).

Extracción-Transformación-Carga

- En el área de preparación, se procesan los datos.
- Se transforman y consolidan para el caso de uso analítico.
- Puede implicar las siguientes tareas:
 - Filtrar, limpiar, deduplicar, validar y autenticar los datos.
 - Realizar cálculos, traducciones o resúmenes de datos.
 - Convertir monedas, unidades de medida, editar cadenas de texto, cambiar encabezados de fila y columna.
 - Realizar auditorías para garantizar calidad.
 - Eliminar, cifrar o proteger datos restringidos (por gobierno o industria). Procesos de anonimización si corresponde.
 - Formatear datos para que coincidan con el esquema de destino de los datos.

Extracción-Transformación-Carga

- Los datos se mueven desde el área de preparación a un almacén de datos de destino.
- Implica la carga inicial, seguida de cargas periódicas incrementales y eventualmente actualizaciones completas para borrar y reemplazar datos.
- En la mayoría de las organizaciones, es un proceso:
 - Automatizado
 - Bien definido
 - Continuo
 - Controlado por lotes (hay excepciones)
- Normalmente ETL se lleva a cabo fuera del horario laboral.

Otros Métodos de Integración de Datos


- Change Data Capture (CDC):
 - Identifica y captura solo los datos que han cambiado en el origen y los mueve al destino.
 - También se puede usar para mover datos desde el Data Lake u otro repositorio en tiempo real.
- Replicación de Datos:
 - Copia los cambios en las fuentes en tiempo real o en lotes a una base central.
 - Con frecuencia se utiliza para copias de seguridad.
- Virtualización de Datos:
 - Se crea una capa de abstracción con una vista de los datos unificada, integrada y totalmente utilizable, sin copiar.
- Stream Data Integration (SDI):
 - Consume flujos de datos en tiempo real, los transforma y los carga para su análisis.

Beneficios de ETL

- Mejoran la calidad al realizar una limpieza de datos antes de cargarlos en un repositorio diferente.
- ETL se recomienda con mayor frecuencia para crear repositorios de datos de destino más pequeños que requieren actualización menos frecuentes.
- Otros métodos de integración de datos (ELT, captura de datos modificados y virtualización) se utilizan para integrar volúmenes cada vez mayores de datos que cambian o flujos de datos en tiempo real.


DATA WAREHOUSE

Data Warehouse




Data Warehouse

- Repositorio central de datos
- Formato estructurado
- Datos previamente procesados
- Objetivo: análisis e inteligencia de negocios.




Data Warehouse

Esquema de un Data Warehouse




Data Warehouse

Esquema de un Data Warehouse




Herramientas de Visualización



Data Mart


- Repositorio de datos con información específica de una unidad de negocio.
- Contiene un subconjunto pequeño y específico de los datos que la organización almacena.
- Datos orientados a analizar información específica de cada departamento eficientemente.
- Objetivo: brinda datos resumidos a partes interesadas clave.

OLAP: Online Analytical Processing




OLAP: Online Analytical Processing


Sample OLAP Cube:




OLAP: Online Analytical Processing




OLAP: Online Analytical Processing



OLAP: Online Analytical Processing



OLAP: Online Analytical Processing



DATA LAKE

Considerando las necesidades modernas de la analítica y aprovechamiento de los datos:


¿Cuál podría considerarse la limitación principal de los Data Warehouse?

- Repositorio central de datos.
- Formato estructurado, semi y no estructurado, sin procesar.
- Desafío: los datos se almacenan sin supervisión de los contenidos (catalogar y proteger los datos).
- Objetivo: se pueden ejecutar diferentes tipos de análisis, desde paneles y visualización hasta análisis en tiempo real y machine learning.

Principios de Data Lakes:

- Almacenamiento en formato nativo.
- Centralización e infraestructura escalable.
- Schema on Read:
 - Los datos no son validados ni estructurados durante el proceso de escritura.
- In-Place Analytics
 - Los datos pueden ser leídos de distinta forma desde el mismo archivo.
- ELT vs. ETL
- Acceso flexible y democratización de datos.
- Gobernanza, seguridad y calidad.

Data Lake




Conceptos importantes:

- Archivos inmutables.
- Bucket o Container.
- Blobs u Objects.


¿Cuales son los desafíos principales del Data Lake?

DATA LAKEHOUSE

Data Lakehouse




Data Lakehouse




ESQUEMAS DE ARQUITECTURA DE DATOS

Esquema de Arquitectura



Áreas de Roles Asociados



¡Muchas Gracias!