

CIENCIA DE DATOS



UNIDAD 2: ETL - PREPROCESAMIENTO

Mgtr. Ing. Mariano Martín Gualpa

Tipos de Variables:

- Variables Categóricas
- Variables Numéricas
- Variables Mixtas
- Variables Fecha-Hora

Tipos de Variables:

- **Variables Categóricas**
 - Nominal
 - Ordinal
 - Dicotómica vs Politómica
- Variables Numéricas
- Variables Mixtas
- Variables Fecha-Hora

Tipos de Variables:

- Variables Categóricas
- **Variables Numéricas**
 - Continuas
 - Discretas
- Variables Mixtas
- Variables Fecha-Hora

Tipos de Variables:

- Variables Categóricas
- Variables Numéricas
- **Variables Mixtas**
 - Números o Categorías
 - Números y Categorías
- Variables Fecha-Hora

Tipos de Variables:

- Variables Categóricas
- Variables Numéricas
- Variables Mixtas
- **Variables Fecha-Hora**
 - Fecha
 - Hora
 - Fecha y Hora

Métodos de Preprocesamiento:

- Limpieza de Datos.
- Integración de Datos y Transformación de Datos.
- Reducción de Datos.
- Discretización y Generación de Jerarquías Conceptuales.


Características indeseables en los datos

- Faltantes
- Irregulares u Outliers
- Inconsistentes
- Innecesarios

Características indeseables en los datos Valores Faltantes




Ejemplos de datos perdidos o faltantes

Edad	Género	Peso	Estatura	Servicio de salud	Enfermedades previas	Vacunas
5	F	38		1	1	2
6	M	29	123	2	2	1
12	M	38	121	2		
7	F	43	119	1	1	2
5	M	42	126	1	2	1
9	M	49	140	1	2	1
	F	22	111	1	2	2
6	F	20	110	1	2	2
9	M	38	133		1	1
9	F		136	1	2	1
4	F	24	106	1	2	
6	M	48	101	1	1	2
5	M	28	122	1	1	1
8	M	21	111	2	2	1
4						
8	F	28	110	2	2	2
4	M		125	2	1	1
4	M	25	140	2	1	2
8	F	50	132	1		1
5		29	121	2	1	2
11				1	2	
12	F	45	118	2	2	1
4	F	28		2	2	1
8	M	43	127		1	2



- Atributos no disponibles
- No se consideraron importantes
- No se grabaron por malentendidos o fallas.
- Se perdió el historial de modificaciones

Características indeseables en los datos Valores Irregulares u Outliers



- Instrumentos de recolección defectuosos
- Errores humanos o computadoras en el ingreso de los datos
- Limitaciones tecnológicas, por ejemplo tamaño de buffer.

Características indeseables en los datos

Valores Inconsistentes



¿Córdoba, Cordoba,
cordoba, CORDOBA?



- Convención de nombres o códigos
- Tuplas duplicadas

Tipos de Errores:

- Datos Incompletos
- Datos con Ruido
- Datos Inconsistentes

Fuentes de Errores:

- Datos Incompletos:
 - Atributos no siempre disponibles.
 - No incluidos inicialmente por considerarse irrelevantes.
 - No registrados por malentendidos o fallas en equipos.
 - Falla el registro histórico de actualizaciones del dato.
 - Podrían necesitar inferirse.
- Datos con Ruido
- Datos Inconsistentes

Fuentes de Errores:


- Datos Incompletos
- Datos con Ruido: valores incorrectos en los atributos.
 - Instrumentos de recolección defectuosos.
 - Errores durante el ingreso (humanos o equipos).
 - Limitaciones tecnológicas (ej: tamaño de buffer en Tx).
- Datos Inconsistentes

Tipos de Errores:

- Datos Incompletos
- Datos con Ruido
- Datos Inconsistentes:
 - Inconsistencias en convenciones de nombres o códigos.
 - Tuplas duplicadas.

Pasos correspondientes al pre-procesamiento de datos:

- Limpieza de los datos.
- Integración de los datos.
- Transformación de los datos.
- Reducción de datos.




Valores Faltantes:

Algunas tuplas no tienen valores registrados para algunos atributos.

Técnicas:

- Ignorar la tupla completa.
- Llenar el valor manualmente.
- Usar una constante global para llenar el valor.
- Usar una medida estadística para completar.
- Usar la media de los atributos para todos los ejemplos pertenecientes a la misma clase de la tupla con valor faltante.
- Usar el valor más probable para completar.




Valores Faltantes:

Algunas tuplas no tienen valores registrados para algunos atributos.

Técnicas:

- Ignorar la tupla completa.
- Llenar el valor manualmente.
- Usar una constante global para llenar el valor.
- Usar una medida estadística para completar.
- Usar la media de los atributos para todos los ejemplos pertenecientes a la misma clase de la tupla con valor faltante.
- Usar el valor más probable para completar.



Valores Faltantes:


Algunas tuplas no tienen valores registrados para algunos atributos.

Técnicas:

Estos métodos no influyen en los datos



- Ignorar la tupla completa.
- Llenar el valor manualmente.
- Usar una constante global para llenar el valor.
- Usar una medida estadística para completar.
- Usar la media de los atributos para todos los ejemplos pertenecientes a la misma clase de la tupla con valor faltante.
- Usar el valor más probable para completar.




Datos con Ruido:

Error aleatorio o variación en una variable medida que afecta la calidad de los datos.

Técnicas:

- Encajado (binning).
- Agrupar.
- Combinación de Inspección Humana y Computarizada.
- Regresión.
- Discretización (similar a encajado, jerarquías conceptuales).




Datos Inconsistentes:

Inconsistencias en los datos obtenidos de determinadas transacciones.

Técnicas:

- Chequeo de lo ingresado.
- Rutinas para detección de inconsistencias.
 - Conocer dependencias funcionales entre atributos.



Integración de Datos:

- Asegurar que claves en diferentes fuentes se refieren a la misma entidad.
- Redundancias:
 - Puede haber por tuplas o por columnas.
 - Correlación

$$r_{A,B} = \frac{\sum (A - \bar{A}) \cdot (B - \bar{B})}{(n-1) \cdot \sigma_A \cdot \sigma_B}$$

- Valores de diferentes fuentes pueden diferir (ej: unidad de medida).

-2, 32, 100, 59, 48 → 0.02, 0.32, 1.00, 0.59, 0.48
Data Transformation

Transformación de Datos:

- Suavizamiento (smoothing):
 - Utilizando binning, clustering y regresión.
- Agregación.
- Generalización de los Datos (ej: utilizando jerarquías conceptuales).
- Normalización.
 - Min-Max
 - Z-Score
 - Ajuste decimal
- Construcción de Atributos.




INTEGRACIÓN Y TRANSFORMACIÓN DE DATOS

UNIDAD 2: ETL (PRE-PROCESAMIENTO)

Transformación de Datos:

- **Suavizamiento (smoothing):**
 - Utilizando binning, clustering y regresión.
- Agregación.
- Generalización de los Datos (ej: utilizando jerarquías conceptuales).
- Normalización.
 - Min-Max
 - Z-Score
 - Ajuste decimal
- Construcción de Atributos.

-2, 32, 100, 59, 48 → 0.02, 0.32, 1.00, 0.59, 0.48
Data Transformation




INTEGRACIÓN Y TRANSFORMACIÓN DE DATOS

UNIDAD 2: ETL (PRE-PROCESAMIENTO)


-2, 32, 100, 59, 48 → 0.02, 0.32, 1.00, 0.59, 0.48
Data Transformation

Transformación de Datos:

- Suavizamiento (smoothing):
 - Utilizando binning, clustering y regresión.
- Agregación.
- Generalización de los Datos (ej: utilizando jerarquías conceptuales).
- Normalización.
 - Min-Max
 - Z-Score
 - Ajuste decimal
- Construcción de Atributos.



Sample OLAP Cube:




INTEGRACIÓN Y TRANSFORMACIÓN DE DATOS

-2, 32, 100, 59, 48 → 0.02, 0.32, 1.00, 0.59, 0.48
Data Transformation

Transformación de Datos:

- Suavizamiento (smoothing):
 - Utilizando binning, clustering y regresión.
- Agregación.
- Generalización de los Datos (ej: utilizando jerarquías conceptuales).
- Normalización.
 - Min-Max
 - Z-Score
 - Ajuste decimal
- Construcción de Atributos.






INTEGRACIÓN Y TRANSFORMACIÓN DE DATOS

UNIDAD 2: ETL (PRE-PROCESAMIENTO)

-2, 32, 100, 59, 48 → 0.02, 0.32, 1.00, 0.59, 0.48
Data Transformation

Transformación de Datos:


- Suavizamiento (smoothing):
 - Utilizando binning, clustering y regresión.
- Agregación.
- Generalización de los Datos (ej: utilizando jerarquías conceptuales).
- **Normalización.**
 - Min-Max
 - Z-Score
 - Ajuste decimal
- Construcción de Atributos.



Min-Max $\Rightarrow X'_A = \frac{X_A - \text{Min}_A}{\text{Max}_A - \text{Min}_A}$

Z-Score $\Rightarrow X'_A = \frac{X_A - \mu_A}{\sigma_A}$

Ajuste decimal $\Rightarrow X'_A = \frac{X_A}{10^j}$



Donde j es el entero más chico para el cual $\text{Max}(|X'_A|) < 1$

INTEGRACIÓN Y TRANSFORMACIÓN DE DATOS

Transformación de Datos:

- Suavizamiento (smoothing):
 - Utilizando binning, clustering y regresión.
- Agregación.
- Generalización de los Datos (ej: utilizando jerarquías conceptuales).
- Normalización.
 - Min-Max
 - Z-Score
 - Ajuste decimal
- **Construcción de Atributos.**

-2, 32, 100, 59, 48 → 0.02, 0.32, 1.00, 0.59, 0.48
Data Transformation



id	X
1	a
2	c
3	a
4	b
5	a
6	c
7	c
8	b

One-Hot Encoding


id	X = a	X = b	X = c
1	1	0	0
2	0	0	1
3	1	0	0
4	0	1	0
5	1	0	0
6	0	0	1
7	0	0	1
8	0	1	0

Dummy Encoding

id	X = a	X = b
1	1	0
2	0	0
3	1	0
4	0	1
5	1	0
6	0	0
7	0	0
8	0	1



Estrategias de Reducción de Datos:

- Agregado de Cubo de Datos.
- Reducción de Dimensión.
- Compresión de Datos (codificación).
- Reducción Numérica.
- Discretización y Generación de Jerarquías Conceptuales




Estrategias de Reducción de Datos:

- Agregado de Cubo de Datos.
- Reducción de Dimensión.
- Compresión de Datos (codificación).
- Reducción Numérica.
- Discretización y Generación de Jerarquías Conceptuales




Sample OLAP Cube:



REDUCCIÓN DE DATOS


Estrategias de Reducción de Datos:

- Agregado de Cubo de Datos.
- Reducción de Dimensión.
- Compresión de Datos (codificación).
- Reducción Numérica.
- Discretización y Generación de Jerarquías Conceptuales



Feature Selection


All Features



Feature Selection



Final Features




Name	Employee ID	No. of year experience	Previous salary	Salary
Rahul	1	2	20000	40000
Aman	34	3	30000	50000
Ritika	31	5	50000	70000

↓ Not useful ↓ Not useful

No. of year experience	Previous salary	Salary
2	20000	40000
3	30000	50000
5	50000	70000





Dimensional Reduction



REDUCCIÓN DE DATOS

Estrategias de Reducción de Datos:






- Agregado de Cubo de Datos.
- Reducción de Dimensión.
- Compresión de Datos (codificación).
- Reducción Numérica.
- Discretización y Generación de Jerarquías Conceptuales



REDUCCIÓN DE DATOS

Estrategias de Reducción de Datos:



- Agregado de Cubo de Datos.
- Reducción de Dimensión.
- Compresión de Datos (codificación).
- **Reducción Numérica.**
- Discretización y Generación de Jerarquías Conceptuales



REDUCCIÓN DE DATOS

Estrategias de Reducción de Datos:

- Agregado de Cubo de Datos.
- Reducción de Dimensión.
- Compresión de Datos (codificación).
- Reducción Numérica.
- Discretización y Generación de Jerarquías Conceptuales



¡Muchas gracias!