

Ciencia de Datos



Unidad 4: Aprendizaje Supervisado

Tema: Regresión Lineal

Mgtr. Ing. Mariano Martín Gualpa (mgualpa@frc.utn.edu.ar)


Temario de la Clase



- Fundamentos Aprendizaje Automático.
- Aprendizaje Automático Supervisado.
- Repaso de conceptos básicos.
- Problemática a resolver.
 - Visión General del Proceso.
 - Aspectos a considerar.
- El Modelo de Regresión Lineal.
 - Regresión Lineal Simple.
 - Regresión Lineal Múltiple.
- Aprendizaje con Regresión Lineal.
- Evaluación del Desempeño del Modelo de Regresión.
- **Práctica de Programación 1.**
- Regresión Polinomial.
- Error de Sesgo (Bias) vs Error de Varianza (Variance).
- Complejidad del Modelo.
- Efecto de Escalar Variables
- **Práctica de Programación 2.**
- Parámetro de Regularización.
 - Ridge
 - LASSO
 - ElasticNet.
- Elementos que Ayudan a Mejorar el Modelo
- Otros Algoritmos para Regresión.


Fundamentos del Aprendizaje Automático

Paradigma Tradicional:




Aprendizaje Automático

Paradigma Tradicional:




Aprendizaje Automático:




Aprendizaje Automático

Paradigma Tradicional:



Aprendizaje Automático:



Aprendizaje Automático



Tipos de Aprendizaje:

- Aprendizaje Supervisado.
- Aprendizaje No Supervisado.
- Aprendizaje Semi-Supervisado.
- Aprendizaje por Refuerzo.

Aprendizaje Automático

Tipos de Aprendizaje:




- **Aprendizaje Supervisado.**
 - Datos + Salida
 - Salida:
 - Regresión: Variable Continua.
 - Clasificación: Variable categórica.
- Aprendizaje No Supervisado.
- Aprendizaje Semi-Supervisado.
- Aprendizaje por Refuerzo.



Aprendizaje Automático

Tipos de Aprendizaje:


- Aprendizaje Supervisado.
- **Aprendizaje No Supervisado.**
 - Datos con salida no disponible.
 - Clustering.
 - Asociación.
 - Detección de anomalías.
 - Reducción de dimensionalidad.
- Aprendizaje Semi-Supervisado.
- Aprendizaje por Refuerzo.



Aprendizaje Automático

Tipos de Aprendizaje:


- Aprendizaje Supervisado.
- Aprendizaje No Supervisado.
- **Aprendizaje Semi-Supervisado.**
 - Datos + algunas salidas
 - Clasificación.
 - Clustering.
- Aprendizaje por Refuerzo.



Aprendizaje Automático

Tipos de Aprendizaje:


- Aprendizaje Supervisado.
- Aprendizaje No Supervisado.
- Aprendizaje Semi-Supervisado.
- **Aprendizaje por Refuerzo.**
 - Entorno y recompensas.
 - Establecer que es un estado deseado.
 - Problemas de búsqueda de políticas.




[Figure source: Sutton & Barto, 1998]

Aprendizaje Automático Supervisado

Paradigma Tradicional:




Aprendizaje Automático:



Aprendizaje Automático Supervisado

Paradigma Tradicional:




Aprendizaje Automático:



Aprendizaje Automático Supervisado

Paradigma Tradicional:




Aprendizaje Automático:




Aprendizaje Automático Supervisado

Paradigma Tradicional:




Aprendizaje Automático:




Aprendizaje Automático Supervisado

Paradigma Tradicional:




Aprendizaje Automático:



Aprendizaje Automático Supervisado


Paradigma Tradicional:




Aprendizaje Automático:



Aprendizaje Automático Supervisado



Aprendizaje Automático Supervisado



Repaso de Algunos Temas Básicos

Repaso de Algunos Temas Básicos

- Escalar: en general, se refiere a un número real.

$$\alpha = 0,5 \quad ; \quad \lambda = 3 \quad ; \quad x_1 = 1.500$$

- Vector: una tupla de m elementos (números en nuestro caso).

$$\mathbf{x} = (x_1, x_2, x_3, \dots, x_m)$$

- Matriz: arreglo bidimensional de números.

$$X = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_m^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \dots & x_m^{(2)} \\ \dots & \dots & \dots & \dots \\ x_1^{(n)} & x_2^{(n)} & \dots & x_m^{(n)} \end{bmatrix} = \begin{bmatrix} \mathbf{x}^{(1)} \\ \mathbf{x}^{(2)} \\ \dots \\ \mathbf{x}^{(n)} \end{bmatrix}$$

Problemática a Resolver

Problemática a Resolver

- La meta de la regresión lineal es modelar relaciones entre un conjunto de variables explicativas (explanatory variables) y una variable objetivo **continua** (target variable).
- Variables:
 - Variables explicativas: $\mathbf{x} = (x_1, x_2, x_3, \dots, x_m)$
 - Variable objetivo: y
- Meta: encontrar la mejor función h .
 - Tal que aproxime $\hat{y} = h(\mathbf{x})$
- En regresión lineal, el modelo h que relaciona estas variables es un modelo lineal.
- ¿Desde donde? A partir de un conjunto suficientemente grande de pares $\mathbf{x}$ e y .

Visión General del Proceso

1. Construir el conjunto de ejemplos de entrenamiento.
 1. Recolectar datos.
 2. Del conjunto, establecer características discriminativas, relevantes, que no sean fácilmente afectadas por el ruido. $\leq$ Análisis Exploratorio.
2. Elegir un **modelo** que constituya una generalización aproximada, determinando un espacio de hipótesis.
3. Elegir una **función de error** que permita discriminar según el desempeño de las diferentes hipótesis.
4. Elegir un **algoritmo** de entrenamiento que permita seleccionar la mejor hipótesis.
5. Realizar el proceso de entrenamiento.
6. Evaluar modelos obtenidos y seleccionar.

El Modelo de Regresión Lineal


El Modelo de Regresión Lineal

Modelo de Regresión Lineal Simple:

$$\hat{y} = w_0 + w_1 x$$

w_0 : coordenada al origen (intercept).

w_1 : coeficiente de peso de la variable (slope).




El Modelo de Regresión Lineal

Modelo de Regresión Lineal Múltiple:

$$\hat{y} = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m$$

$$\hat{y} = \sum_{i=0}^m w_i x_i = \mathbf{w}^T \mathbf{x}$$



w: vector de coeficientes de pesos correspondientes a las variables.

x: vector de variables independientes.

w_0 : coordenada al origen (intercept).

$x_0 = 1$


Aprendizaje con Regresión Lineal

Aprendizaje con Regresión Lineal

Modelo de Regresión Lineal:

$$\hat{y} = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m = \sum_{j=0}^m w_jx_j = \mathbf{w}^T \mathbf{x}$$

$$J(w) = \frac{1}{2} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2$$



El problema del aprendizaje con este modelo puede plantearse básicamente como:

$$\operatorname{argmin}_{\mathbf{w}} \left[\frac{1}{2} \sum_{i=1}^n \left(y^{(i)} - w_0 - \sum_{j=1}^m w_j x_j^{(i)} \right)^2 \right]$$

Ordinary Least Square


Supuestos de la Regresión Lineal

Supuestos de la Regresión Lineal

Assumptions of Linear Regression


1. Linearity

(Linear relationship between Y and each X)




2. Homoscedasticity

(Equal variance)




3. Multivariate Normality

(Normality of error distribution)



4. Independence

(of observations. Includes "no autocorrelation")



5. Lack of Multicollinearity

(Predictors are not correlated with each other)

$$X_1 + X_2$$

$$X_1 \sim X_2$$

6. Absence of endogeneity

(No correlation between predictors and errors.)



Supuestos de la Regresión Lineal

Linealidad:

- La relación entre las variables dependientes e independiente es lineal.




Imagen: <https://www.geeksforgeeks.org/machine-learning/assumptions-of-linear-regression>

Supuestos de la Regresión Lineal

Homocedasticidad de residuos:

- Los residuos (las diferencias entre los valores observados y predichos) deben tener una varianza constante en todos los niveles de la(s) variable(s) independiente(s).
- Es decir: la dispersión de los errores debe ser relativamente uniforme, independientemente del valor del predictor.




Imagen: <https://www.geeksforgeeks.org/>




Imagen: <https://www.wikipedia.org/>

Supuestos de la Regresión Lineal




Imagen: <https://www.fuenterrebollo.com/Economicas/TEORICA-I/2-bidimensional.pdf>

Supuestos de la Regresión Lineal

Normalidad multivariante - Distribución normal:

- Los residuos (las diferencias entre los valores observados y predichos) deben seguir una distribución normal al considerar múltiples predictores en conjunto.









Imagen: <https://www.geeksforgeeks.org/>

Supuestos de la Regresión Lineal

Independencia de los errores:

- Los residuos (las diferencias entre los valores observados y predichos) no estén correlacionados entre sí.




Imagen: <https://www.analyticsvidhya.com/>




Imagen: <https://www.geeksforgeeks.org/>

Supuestos de la Regresión Lineal

Falta de multicolinealidad:

- Las variables independientes no están altamente correlacionadas entre sí.



Imagen: <https://www.kaggle.com/code/abonaplata/analisis-exploratorio-de-datos-con-python/notebook>





Imagen: <https://www.codetodevs.com/correlacion-variables-pairplot-seaborn/>


Supuestos de la Regresión Lineal

Ausencia de endogeneidad:

- Las variables independientes del modelo de regresión no deben estar correlacionadas con el término de error.
- Si se viola este supuesto, se obtienen estimaciones sesgadas e inconsistentes de los coeficientes de regresión.



Typical regression



Errors in variables

Imagen: <https://blog.shakirm.com/>










Imagen: <https://www.geeksforgeeks.org/>

Evaluación de Desempeño del Modelo de Regresión

Evaluación de Desempeño del M. de Reg.

Gráfico de Residuos: $e^{(i)} = \hat{y}^{(i)} - y^{(i)}$




Evaluación de Desempeño del M. de Reg.

Modelo de Regresión:

$$y(\mathbf{x}, \mathbf{w}) = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m = \hat{y}$$

Gráfico QQ:



Evaluación de Desempeño del M. de Reg.

MSE: Media del Error Cuadrático (Mean Squared Error)

$$MSE = \frac{1}{n} \sum_{i=1}^n \left(y^{(i)} - \hat{y}^{(i)} \right)^2$$

RMSE: Raíz de la Media del Error Cuadrático (Root Mean Squared Error)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n \left(y^{(i)} - \hat{y}^{(i)} \right)^2}$$

R²: Coeficiente de Determinación

$$R^2 = 1 - \frac{SSE}{SST}$$

SSE: Sum of squared errors

SST: Total sum of squared

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{\sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2}{\sum_{i=1}^n (y^{(i)} - \mu_y)^2}$$

$$R^2 = 1 - \frac{\frac{1}{n} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2}{\frac{1}{n} \sum_{i=1}^n (y^{(i)} - \mu_y)^2}$$

$$R^2 = 1 - \frac{MSE}{Var(y)}$$

Práctica de Programación 1


Regresión Polinomial

El Modelo de Regresión Lineal

Modelo de Regresión Polinomial:

$$\hat{y} = w_0 + w_1x + w_2x^2 + \dots + w_dx^d$$

d: grado del polinomio



Transformación: Dado un valor para d por cada $x(i)$ aplicamos una transformación $\mathbb{R} \rightarrow \mathbb{R}^{1 \times (d+1)}$ tal que:

$x \rightarrow (x_0, x_1, x_2, \dots, x_d)$ donde $(x_0, x_1, x_2, \dots, x_d)$ será $(x^0, x^1, x^2, \dots, x^d)$

Error de Sesgo (Bias) vs Error de Varianza


Entendiendo el Underfitting y Overfitting

Error de Sesgo vs Error de Varianza

Los diferentes modelos pueden tener diferentes “grados de libertad”.


Modelo:

$$\hat{y} = w_0 + w_1x + w_2x^2 + \dots + w_mx^m$$





Error de Sesgo vs Error de Varianza

Modelo: $\hat{y} = w_0 + w_1x + w_2x^2 + \dots + w_mx^m$






Error de Sesgo vs Error de Varianza

Modelo: $\hat{y} = w_0 + w_1x + w_2x^2 + \dots + w_mx^m$







Error de Sesgo vs Error de Varianza

Modelo: $\hat{y} = w_0 + w_1x + w_2x^2 + \dots + w_mx^m$








Error de Sesgo vs Error de Varianza

$$\text{Modelo: } \hat{y} = w_0 + w_1x + w_2x^2 + \dots + w_mx^m$$









Error de Sesgo vs Error de Varianza

$$\text{Modelo: } \hat{y} = w_0 + w_1x + w_2x^2 + \dots + w_mx^m$$









Error de Sesgo vs Error de Varianza

$$\text{Modelo: } \hat{y} = w_0 + w_1x + w_2x^2 + \dots + w_mx^m$$





Error de Sesgo vs Error de Varianza

¿cómo evolucionó el error?





Error de Sesgo vs Error de Varianza



Resultados con un Modelo Polinómico de Grado $m = 1$





Resultados con un Modelo Polinómico de Grado $m = 2$




Resultados con un Modelo Polinómico de Grado $m = 3$



Resultados con un Modelo Polinómico de Grado $m = 9$





Error vs Complejidad del Modelo



Efecto de Escalar las Variables

Efecto del Escalar las Variables



Práctica de Programación 2

Término de Regularización

Modelos de Regresión Lineal Regularizada

Regresión Lineal:

$$y(\mathbf{x}, \mathbf{w}) = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m = \hat{y}$$

$$J(w) = \frac{1}{2} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2$$

Linear Regression		Linear Regression	
0	467.635115	0	4.676351e+02
1	1286.863879	1	9.182147e+02
2	-3550.444588	2	-7.108457e+03
3	4291.232580	3	9.959076e+04
4	-2704.579324	4	-6.177826e+05
5	892.585407	5	1.915431e+06
		6	-3.309102e+06
		7	3.252262e+06
		8	-1.704089e+06
		9	3.700996e+05


Modelos de Regresión Lineal Regularizada

Ridge Regression:

$$y(\mathbf{x}, \mathbf{w}) = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m = \hat{y}$$

$$J(\mathbf{w})_{\text{Ridge}} = \sum_{i=1}^n \left(y^{(i)} - \hat{y}^{(i)} \right)^2 + \lambda \|\mathbf{w}\|_2^2$$

$$L2 : \lambda \|\mathbf{w}\|_2^2 = \lambda \sum_{j=1}^m (w_j)^2$$



Modelos de Regresión Lineal Regularizada




Ridge Regression:

	Linear Regression	Ridge_alpha:0.001000	Ridge_alpha:0.010000	Ridge_alpha:0.100000	Ridge_alpha:1.000000	Ridge_alpha:10.000000	Ridge_alpha:100.000000
0	4.676351e+02	467.635115	467.635115	467.635115	467.635115	467.635115	467.635115
1	9.182147e+02	1087.147939	856.153640	555.456633	282.153746	105.974712	31.320310
2	-7.108457e+03	-2069.093427	-1226.073416	-491.972802	-77.722716	20.724215	19.596553
3	9.959076e+04	437.598579	-94.531199	-238.973305	-104.922587	-3.638244	14.639590
4	-6.177826e+05	1086.627465	420.191056	31.477717	-64.309397	-6.893663	12.501644
5	1.915431e+06	359.875316	349.760577	152.228707	-20.112609	-2.761211	11.589291
6	-3.309102e+06	-390.782128	107.202830	159.820391	14.687365	3.743318	11.227827
7	3.252262e+06	-590.484630	-73.993225	103.274550	39.450138	10.670201	11.114711
8	-1.704089e+06	-222.685482	-115.055198	15.724077	56.075576	17.247554	11.108833
9	3.700996e+05	518.194437	-14.487553	-83.569342	66.600824	23.192061	11.143306

Modelos de Regresión Lineal Regularizada

Ridge Regression:




Modelos de Regresión Lineal Regularizada

LASSO (Least Absolute Shrinkage and Selection Operator):

$$y(\mathbf{x}, \mathbf{w}) = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m = \hat{y}$$

$$J(\mathbf{w})_{LASSO} = \sum_{i=1}^n \left(y^{(i)} - \hat{y}^{(i)} \right)^2 + \lambda \|\mathbf{w}\|_1$$

$$L1 : \lambda \|\mathbf{w}\|_1 = \lambda \sum_{j=1}^m |w_j|$$



Modelos de Regresión Lineal Regularizada




LASSO (Least Absolute Shrinkage and Selection Operator):

	Linear Regression	LASSO_alpha:0.001000	LASSO_alpha:0.100000	LASSO_alpha:1.000000	LASSO_alpha:10.000000	LASSO_alpha:100.000000
0	4.676351e+02	467.635115	467.635115	467.635115	467.635115	467.635115
1	9.182147e+02	1135.088216	918.812610	538.600665	145.302749	73.570604
2	-7.108457e+03	-2028.984069	-1444.088761	-560.228623	-0.000000	0.000000
3	9.959076e+04	-733.148004	0.000000	-0.000000	-0.000000	0.000000
4	-6.177826e+05	3492.727493	812.286493	0.000000	-0.000000	0.000000
5	1.915431e+06	-0.000000	0.000000	0.000000	0.000000	0.000000
6	-3.309102e+06	-2656.819189	-0.000000	137.859215	0.000000	0.000000
7	3.252262e+06	0.000000	-0.000000	86.620733	0.000000	0.000000
8	-1.704089e+06	1128.018427	-53.305649	0.000000	0.000000	0.000000
9	3.700996e+05	-117.924673	-22.858699	0.000000	25.743236	0.000000


Modelos de Regresión Lineal Regularizada

LASSO (Least Absolute Shrinkage and Selection Operator):




Modelos de Regresión Lineal Regularizada

Regresión Lineal vs Ridge vs LASSO



Modelos de Regresión Lineal Regularizada

Regresión Lineal vs Ridge vs LASSO



Modelos de Regresión Lineal Regularizada

ElasticNet:

$$y(\mathbf{x}, \mathbf{w}) = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m = \hat{y}$$

$$J(\mathbf{w})_{ElasticNet} = \sum_{i=1}^n \left(y^{(i)} - \hat{y}^{(i)} \right)^2 + \lambda_1 \|\mathbf{w}\|_1^2 + \lambda_2 \|\mathbf{w}\|_1$$

$$J(\mathbf{w})_{ElasticNet} = \sum_{i=1}^n \left(y^{(i)} - \hat{y}^{(i)} \right)^2 + \lambda_1 \sum_{j=1}^m (w_j)^2 + \lambda_2 \sum_{j=1}^m |w_j|$$

En Sklearn o en R:

$$J(\mathbf{w})_{ElasticNet} = \sum_{i=1}^n \left(y^{(i)} - \hat{y}^{(i)} \right)^2 + \lambda \left((1 - r l_1) \sum_{j=1}^m (w_j)^2 + r l_1 \sum_{j=1}^m |w_j| \right)$$

Elementos que Ayudan a Mejorar el Modelo Obtenido

Elementos que Ayudan a Mejorar el Modelo

Existen muchos elementos que pueden ayudar con el sobreajuste son:



- Validación cruzada adecuada.
- Complejidad del modelo.
- Aumentar la cantidad de datos.
- Agregar regularización para penalizar los w_j en la loss function.
 - Afecta al tamaño de los coeficientes w_j .
 - Afecta a la cantidad de términos en el polinomio.
- Normalizar las features (x_i) para que no afecte el orden de magnitud.
- Agregar mas features antes de ajustar el modelo.

Otros Algoritmos para Regresión




Otros Algoritmos para Regresión

Existen otros modelos y algoritmos para regresión:





- Regresión de N vecinos más próximos (Kneighbors Regression).
- Regresión con Árboles de Decisión.
- Regresión con Random Forest.
- Redes Neuronales.
- Entre otras.



¿Preguntas?



$$y = w_0 1 + w_1 x_1 + w_2 x_2 + \dots + w_m x_m$$



¡Muchas gracias!