

Ciencia de Datos



Unidad 4: Aprendizaje Supervisado

Tema: Clasificación. Regresión Logística

Mgtr. Ing. Mariano Martín Gualpa (mgualpa@frc.utn.edu.ar)

Temario de la Clase



- El Problema de Clasificación.
- Introducción Intuitiva a la Regresión Logística.
- Fundamentación Teórica.
- Frontera de Decisión.
- Fronteras No Lineales.
- Interpretación Probabilística.
- Función de Costo para Regresión Logística.
- Término de Regularización.
- **Actividad Práctica**

El Problema de Clasificación

Problemática a Resolver


- La meta de la regresión logística es modelar relaciones entre un conjunto de variables predictoras y una variable objetivo **categorica** (target variable).
- ¿Desde donde? A partir de un conjunto suficientemente grande de pares $\mathbf{x}$ e y .
- Objetivos:
 - Determinar presencia o ausencia de relación entre variables predictoras y la variable dependiente.
 - Predecir la probabilidad de respuesta de cada valor posible, en función de la entrada.
 - Utilizar estas probabilidades para clasificar observaciones futuras.

Variables:

- Variables predictoras o covariables: $\mathbf{x} = (x_1, x_2, x_3, \dots, x_m)$.
- Variable objetivo categórica: y
 - Cantidad de Clases:
 - Clasificación Binaria: dos clases.
 - Clasificación Multiclase: mas de dos clases.
 - Tipo de Variable Categórica:
 - Variable Categórica Nominal.
 - Variable Categórica Ordinal.


Problemática a Resolver

- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función h .
 - Tal $\hat{y} = h(\mathbf{x})$ corresponda a la categoría correcta y con una alta probabilidad.




Problemática a Resolver

- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función h .
 - Tal $\hat{y} = h(\mathbf{x})$ corresponda a la categoría correcta y con una alta probabilidad.



Problemática a Resolver


- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función h .
 - Tal $\hat{y} = h(\mathbf{x})$ corresponda a la categoría correcta y con una alta probabilidad.



Introducción Intuitiva a la Regresión Logística


Introducción Intuitiva a la R. Logística

- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función para predecir y .




Introducción Intuitiva a la R. Logística

- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función para predecir y .



Introducción Intuitiva a la R. Logística


- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función para predecir y .



- Problema:
 - Valores positivos pueden cambiar dramáticamente la pendiente.
 - Variable de salida y solo puede ser 0 ó 1.
 - La hipótesis puede tomar valores mas grandes que 1 y menores que 0.


Introducción Intuitiva a la R. Logística

- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función para predecir y .





- Función Sigmoide o función Logística.
- Cruza 0,5 en el origen.
- Asintótica a 0 y 1.
- $z = \mathbf{w}^T \mathbf{x}$

Introducción Intuitiva a la R. Logística



Introducción Intuitiva a la R. Logística




Fundamentación Teórica

Fundamentación Teórica

- En regresión lineal, usamos la hipótesis: $h_{\mathbf{w}}(\mathbf{x}) = (\mathbf{w}^T \mathbf{x})$
- En **clasificación**, usamos la hipótesis: $h_{\mathbf{w}}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x})$
 - Definimos $g(z)$ donde z es un número real.
 - z se estima por $\mathbf{w}^T \mathbf{x}$
 - $g(z) = 1 / (1 + e^{-z})$ Función Sigmoide o Logística
 - La hipótesis a utilizar para la salida será:

$$h_{\mathbf{w}}(\mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = \frac{1}{1 + e^{-(w_0 x_0 + w_1 x_1 + \dots + w_m x_m)}}$$




- Nuevamente, nuestro problema es ajustar $\mathbf{w}$ según los datos.

Interpretación


- Dada una entrada $\mathbf{x}$, $h_{\mathbf{w}}(\mathbf{x})$ nos entrega una estimación de probabilidad de que $y = 1$.
- Es decir: $h_{\mathbf{w}}(\mathbf{x}) = P(y = 1 \mid \mathbf{x} ; \mathbf{w})$
- “la probabilidad de que y sea igual a 1, dado $\mathbf{x}$ parametrizado por $\mathbf{w}$ ”.
- En clasificación binaria:
 - $P(y = 1 \mid \mathbf{x} ; \mathbf{w}) + P(y = 0 \mid \mathbf{x} ; \mathbf{w}) = 1$
 - $P(y = 0 \mid \mathbf{x} ; \mathbf{w}) = 1 - P(y = 1 \mid \mathbf{x} ; \mathbf{w})$

$$h_{\mathbf{w}}(\mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = \frac{1}{1 + e^{-(w_0 x_0 + w_1 x_1 + \dots + w_m x_m)}} = g(\mathbf{w}^T \mathbf{x})$$




Frontera de Decisión


Frontera de Decisión




Frontera de Decisión




Frontera de Decisión





Frontera de Decisión

- Permite entender mejor que se calcula y como se ve la función de hipótesis.
- La salida y puede valer 0 ó 1, la función entrega una probabilidad.
- Una forma de usar la salida de h es:
 - $h_w(\mathbf{x}) = P(y = 1 | \mathbf{x}; \mathbf{w}) \geq 0,5$ entonces predecir $y = 1$.
 - Si no, predecir $y = 0$.
- ¿cuál es la condición para $h_w(\mathbf{x}) \geq 0,5$?
 - $g(z) \geq 0,5$ cuando $z \geq 0 \Rightarrow$ si z es positiva, $g(z) \geq 0,5$
 - Recordando que $z = \mathbf{w}^T \mathbf{x} \Rightarrow$ Cuando $\mathbf{w}^T \mathbf{x} \geq 0 \Rightarrow h_w(\mathbf{x}) \geq 0,5$
- Es decir que la hipótesis predice $y = 1$ cuando $\mathbf{w}^T \mathbf{x} \geq 0$
- Por otro lado, la hipótesis predice $y = 0$ cuando $\mathbf{w}^T \mathbf{x} \leq 0$.




$$h_w(\mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = \frac{1}{1 + e^{-(w_0 x_0 + w_1 x_1 + \dots + w_m x_m)}} = g(\mathbf{w}^T \mathbf{x}) = g(z)$$

Frontera de Decisión


- Tenemos $h_{\mathbf{w}}(\mathbf{x}) = g(z) = g(\mathbf{w}^T \mathbf{x})$
 $= g(w_0 x_0 + w_1 x_1 + w_2 x_2)$
- Supongamos:
 - $w_0 = -5$; $w_1 = 1$; $w_2 = 1$
 - Es decir: $\mathbf{w}^T = [-5, 1, 1]$
- Como $z = (\mathbf{w}^T \mathbf{x})$ entonces:
 - Predecimos $y = 1$ si $z \geq 0$, entonces:
$$w_0 x_0 + w_1 x_1 + w_2 x_2 \geq 0$$
$$-5 + 1 x_1 + 1 x_2 \geq 0$$

Se puede reescribir como:

$$(x_1 + x_2) \geq 5$$
- Se decir: si se cumple que $(x_1 + x_2 \geq 5)$ entonces podemos predecir $y = 1$
- Llamaremos **frontera de decisión** (“decision boundary”) a los puntos donde $x_1 + x_2 = 5$



$$h_{\mathbf{w}}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x}) = g(z)$$




Frontera de Decisión


- Tenemos $h_{\mathbf{w}}(\mathbf{x}) = g(z) = g(\mathbf{w}^T \mathbf{x})$
 $= g(w_0 x_0 + w_1 x_1 + w_2 x_2)$
- Supongamos:
 - $w_0 = -5$; $w_1 = 1$; $w_2 = 1$
 - Es decir: $\mathbf{w}^T = [-5, 1, 1]$
- Como $z = (\mathbf{w}^T \mathbf{x})$ entonces:
 - Predecimos $y = 1$ si $z \geq 0$, entonces:
$$w_0 x_0 + w_1 x_1 + w_2 x_2 \geq 0$$
$$-5 + 1 x_1 + 1 x_2 \geq 0$$

Se puede reescribir como:

$$(x_1 + x_2) \geq 5$$
- Se decir: si se cumple que $(x_1 + x_2 \geq 5)$ entonces podemos predecir $y = 1$
- Llamaremos **frontera de decisión** (“decision boundary”) a los puntos donde $x_1 + x_2 = 5$



$$h_{\mathbf{w}}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x}) = g(z)$$




Frontera de Decisión


- Tenemos $h_{\mathbf{w}}(\mathbf{x}) = g(z) = g(\mathbf{w}^T \mathbf{x})$
 $= g(w_0 x_0 + w_1 x_1 + w_2 x_2)$
- Supongamos:
 - $w_0 = -5$; $w_1 = 1$; $w_2 = 1$
 - Es decir: $\mathbf{w}^T = [-5, 1, 1]$
- Como $z = (\mathbf{w}^T \mathbf{x})$ entonces:
 - Predecimos $y = 1$ si $z \geq 0$, entonces:
$$w_0 x_0 + w_1 x_1 + w_2 x_2 \geq 0$$
$$-5 + 1 x_1 + 1 x_2 \geq 0$$

Se puede reescribir como:

$$(x_1 + x_2) \geq 5$$
- Se decir: si se cumple que $(x_1 + x_2 \geq 5)$ entonces podemos predecir $y = 1$
- Llamaremos **frontera de decisión** (“decision boundary”) a los puntos donde $x_1 + x_2 = 5$




$$h_{\mathbf{w}}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x}) = g(z)$$




Frontera de Decisión de No Lineal

Frontera de Decisión No Lineal

- Al igual que en regresión polinomial, se pueden agregar términos de mayor orden.
- Supongamos $h_w(\mathbf{x}) = g(z)$
 $= g(w_0 + w_1x_1 + w_3x_1^2 + w_4x_2^2)$
- Supongamos:
 - $w_0 = -5$; $w_1 = 0$; $w_2 = 0$; $w_3 = 1$; $w_4 = 1$
 - Es decir: $\mathbf{w}^T = [-5, 0, 0, 1, 1]$
- Como $z = (\mathbf{w}^T \mathbf{x})$ entonces:
 - Predecimos $y = 1$ si $z \geq 0$, entonces:
 $w_0x_0 + w_3x_1^2 + w_4x_2^2 \geq 0$
 $-5 + 1x_1^2 + 1x_2^2 \geq 0$
Se puede reescribir como:
 $(x_1^2 + x_2^2) \geq 5$
- Se decir: si se cumple que $(x_1^2 + x_2^2 \geq 5)$ entonces podemos predecir $y = 1$
- Mediante términos de mayor orden polinomial, es posible construir fronteras de decisión mas complejas.




$$h_w(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x}) = g(z)$$




Frontera de Decisión No Lineal

- Al igual que en regresión polinomial, se pueden agregar términos de mayor orden.
- Supongamos $h_{\mathbf{w}}(\mathbf{x}) = g(z) = g(\mathbf{w}^T \mathbf{x})$
 $= g(w_0 + w_1 x_1 + w_3 x_1^2 + w_4 x_2^2)$
- Supongamos:
 - $w_0 = -5$; $w_1 = 0$; $w_2 = 0$; $w_3 = 1$; $w_4 = 1$
 - Es decir: $\mathbf{w}^T = [-5, 0, 0, 1, 1]$
- Como $z = (\mathbf{w}^T \mathbf{x})$ entonces:
 - Predecimos $y = 1$ si $z \geq 0$, entonces:
 $w_0 x_0 + w_3 x_1^2 + w_4 x_2^2 \geq 0$
 $-5 + 1 x_1^2 + 1 x_2^2 \geq 0$
Se puede reescribir como:
 $(x_1^2 + x_2^2) \geq 5$
- Se decir: si se cumple que $(x_1^2 + x_2^2 \geq 5)$ entonces podemos predecir $y = 1$
- Mediante términos de mayor orden polinomial, es posible construir fronteras de decisión mas complejas.



$$h_{\mathbf{w}}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x}) = g(z)$$



Interpretación Probabilística

Interpretación Probabilística

Se va a modelar el **logit** del evento con un modelo lineal:

$$\ln\left(\frac{p_i}{1-p_i}\right) = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m = \sum_{j=0}^m w_jx_j = \mathbf{w}^T \mathbf{x}$$

Despejando el odds:

$$\frac{p_i}{1-p_i} = e^{\mathbf{w}^T \mathbf{x}}$$

Despejando p_i :

$$p_i = P(y_i=1 \mid \mathbf{x}; \mathbf{w}) = \frac{e^{\mathbf{w}^T \mathbf{x}}}{1 + e^{\mathbf{w}^T \mathbf{x}}} = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = \frac{1}{1 + e^{-(w_0x_0 + w_1x_1 + \dots + w_mx_m)}}$$

Función de Costo


Función de Costo (REPASO)

Modelo de **Regresión Lineal**:

$$y = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_mx_m = \sum_{j=0}^m w_jx_j = \mathbf{w}^T \mathbf{x}$$

Función de Costo en **Regresión Lineal**:

$$J(\mathbf{w}) = \frac{1}{2} \sum_{i=1}^n \left(y^{(i)} - \hat{y}^{(i)} \right)^2$$



El problema del aprendizaje (en regresión lineal) con este modelo puede plantearse básicamente como:

$$\underset{\mathbf{w}}{\operatorname{argmin}} \left[\frac{1}{2} \sum_{i=1}^n \left(y^{(i)} - w_0 - \sum_{j=1}^m w_j x_j^{(i)} \right)^2 \right]$$

Ordinary Least Square

Función de Costo en Regresión Logística

- Hipótesis:

$$h_{\mathbf{w}}(\mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = \frac{1}{1 + e^{-(w_0 x_0 + w_1 x_1 + \dots + w_m x_m)}}$$

- Se busca ajustar los parámetros w_j .
- Para ello, se debe definir un problema de optimización.
- Entrenaremos con un conjunto de n ejemplos.

$$(\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots, (\mathbf{x}^{(n)}, y^{(n)})$$

- Cada ejemplo tiene un vector de $m+1$ columnas.

$$\mathbf{x} = (x_0, x_1, \dots, x_m) \quad \text{donde } x_0 = 1$$

- La salida de la variable y pertenece a $\{0, 1\}$

Función de Costo en Regresión Logística



- En regresión lineal, la función de loss es:

$$J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \frac{1}{2} \left(h_{\mathbf{w}}(\mathbf{x}^{(i)}) - y^{(i)} \right)^2$$

- Podemos definir $\text{Cost}(h_{\mathbf{w}}(\mathbf{x}^{(i)}), y^{(i)}) = \frac{1}{2} (h_{\mathbf{w}}(\mathbf{x}^{(i)}) - y^{(i)})^2$
- Entonces queda:

$$J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \text{Cost}(h_{\mathbf{w}}(\mathbf{x}^{(i)}), y^{(i)})$$

- Se trata de una función no convexa cuando usamos la hipótesis de la función Sigmoide (pues no es lineal).
 - Tiene muchos óptimos locales.
 - El gradiente descendente podría no encontrar el mínimo global.
- Se desea una función convexa que facilite convergencia a un mín. global.

Función de Costo en Regresión Logística



- Costo:

$$J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \text{Cost}(h_{\mathbf{w}}(\mathbf{x}^{(i)}), y^{(i)})$$

- Para solucionarlo se utiliza una función Cost() que sea convexa.

$$\text{Cost}(h_{\mathbf{w}}(\mathbf{x}), y) = \begin{cases} -\log(h_{\mathbf{w}}(\mathbf{x})) & \text{si } y = 1 \\ -\log(1 - h_{\mathbf{w}}(\mathbf{x})) & \text{si } y = 0 \end{cases}$$


Función de Costo en Regresión Logística

- Costo:

$$J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \text{Cost}(h_{\mathbf{w}}(\mathbf{x}^{(i)}), y^{(i)})$$

- Para solucionarlo se utiliza una función Cost() que sea convexa.

$$\text{Cost}(h_{\mathbf{w}}(\mathbf{x}), y) = \begin{cases} -\log(h_{\mathbf{w}}(\mathbf{x})) & \text{si } y = 1 \\ -\log(1 - h_{\mathbf{w}}(\mathbf{x})) & \text{si } y = 0 \end{cases}$$



- Cuando $h_{\mathbf{w}}(\mathbf{x}) = 1$, entonces el costo es 0.
- Si la predicción empieza a ser mala, el costo penaliza cada vez mas.
- Propiedades:
 - Si $y = 1$ y $h_{\mathbf{w}}(\mathbf{x}) = 1 \Rightarrow$ el costo es 0.
 - Si $h_{\mathbf{w}}(\mathbf{x})$ se acerca a 0 $\Rightarrow$ el costo tiende a infinito.
- En definitiva: si acierta el costo es 0, pero si $h_{\mathbf{w}}(\mathbf{x}) = 0$ (la predicción $P(y=1|\mathbf{x};\mathbf{w}) = 0$ entonces penaliza gravemente.


Función de Costo en Regresión Logística

- Costo:

$$J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \text{Cost}(h_{\mathbf{w}}(\mathbf{x}^{(i)}), y^{(i)})$$

- Para solucionarlo se utiliza una función Cost() que sea convexa.

$$\text{Cost}(h_{\mathbf{w}}(\mathbf{x}), y) = \begin{cases} -\log(h_{\mathbf{w}}(\mathbf{x})) & \text{si } y = 1 \\ -\log(1 - h_{\mathbf{w}}(\mathbf{x})) & \text{si } y = 0 \end{cases}$$



- Cuando $h_{\mathbf{w}}(\mathbf{x}) = 0$, entonces el costo es 0.
- Si la predicción empieza a ser mala, el costo penaliza cada vez mas.
- Propiedades:
 - Si $y = 0$ y $h_{\mathbf{w}}(\mathbf{x}) = 0 \Rightarrow$ el costo es 0.
 - Si $h_{\mathbf{w}}(\mathbf{x})$ se acerca a 1 $\Rightarrow$ el costo tiende a infinito.
- En definitiva: si acierta el costo es 0, pero si $h_{\mathbf{w}}(\mathbf{x}) = 1$ (la predicción $P(y=1|\mathbf{x};\mathbf{w}) = 1$ entonces penaliza gravemente.


Función de Costo en Regresión Logística

- Costo:

$$J(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \text{Cost}(h_{\mathbf{w}}(\mathbf{x}^{(i)}), y^{(i)})$$

- Para solucionarlo se utiliza una función Cost() que sea convexa.

$$\text{Cost}(h_{\mathbf{w}}(\mathbf{x}), y) = \begin{cases} -\log(h_{\mathbf{w}}(\mathbf{x})) & \text{si } y = 1 \\ -\log(1 - h_{\mathbf{w}}(\mathbf{x})) & \text{si } y = 0 \end{cases}$$



- A los efectos de simplificar la función de costo, juntaremos todo:

$$\text{Cost}(h_{\mathbf{w}}(\mathbf{x}), y) = -y \log(h_{\mathbf{w}}(\mathbf{x})) - (1-y) \log(1 - h_{\mathbf{w}}(\mathbf{x}))$$

- Loss Function:

$$J(\mathbf{w}) = -\frac{1}{n} \left[\sum_{i=1}^n y^{(i)} \log(h_{\mathbf{w}}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\mathbf{w}}(\mathbf{x}^{(i)})) \right]$$

Función de Costo en Regresión Logística



- Loss Function:

$$J(\mathbf{w}) = -\frac{1}{n} \left[\sum_{i=1}^n y^{(i)} \log(h_{\mathbf{w}}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\mathbf{w}}(\mathbf{x}^{(i)})) \right]$$

- Existen muchas posibilidades, pero esta función de costo:
 - Es una función convexa (facilitará encontrar el óptimo global).
 - Puede ser derivada desde la estadística utilizando el principio de estimación de máxima verosimilitud (maximum likelihood estimation).
 - La verosimilitud es una función que mide lo verosímiles que son unos parámetros para un modelo estadístico a partir de un conjunto de observaciones.
 - Esto significa que hay un supuesto Gaussiano relacionado a la distribución de los valores en las x_j .

Término de Regularización

Término de Regularización

- Loss Function:

$$J(\mathbf{w}) = -\frac{1}{n} \left[\sum_{i=1}^n y^{(i)} \log(h_{\mathbf{w}}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\mathbf{w}}(\mathbf{x}^{(i)})) \right]$$

- Regularización L2:

$$J(\mathbf{w}) = -\frac{1}{n} \left[\sum_{i=1}^n y^{(i)} \log(h_{\mathbf{w}}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\mathbf{w}}(\mathbf{x}^{(i)})) \right] + \frac{\lambda}{2n} \sum_{j=1}^m (w_j)^2$$

- Regularización L1:

$$J(\mathbf{w}) = -\frac{1}{n} \left[\sum_{i=1}^n y^{(i)} \log(h_{\mathbf{w}}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\mathbf{w}}(\mathbf{x}^{(i)})) \right] + \frac{\lambda}{n} \sum_{j=1}^m |w_j|$$

¿Preguntas?

