

Ciencia de Datos




UNIDAD 4. CLASIFICACIÓN. ÁRBOLES DE DECISIÓN

Mgtr. Ing. Mariano Martín Gualpa

TEMARIO:



- Introducción
- Definición
- Aplicaciones
- Caso de Estudio
- Algoritmo
- Algoritmo ID3
- Sobreajuste
- Familias de Algoritmos




INTRODUCCIÓN

INTRODUCCIÓN: CLASIFICACIÓN

“Definimos como clasificación el proceso de encontrar un conjunto de modelos (o funciones) que describen y distinguen clases de datos o conceptos, con el propósito de hacer posible utilizarlo para predecir la clase de objeto para el cual su etiqueta de clase es desconocida. El modelo derivado esta basado en el análisis de un conjunto de datos de entrenamiento.” [Jiawei Han y Micheline Kamber]

Árboles de Decisión: Definición

“Un árbol de decisión es un grafo con estructura de árbol, donde cada nodo denota un test sobre un valor de atributo, cada rama representa un resultado del test, y cada hoja representa clases o distribuciones de clases. Los árboles de decisión pueden ser fácilmente convertidos en reglas de clasificación.” [Han Kamber]




Rattle 2018-Oct-29 20:12:03 mgualpa

Árboles de Decisión: Definición

“Un árbol de decisión es un grafo con estructura de árbol, donde cada nodo denota un test sobre un valor de atributo, cada rama representa un resultado del test, y cada hoja representa clases o distribuciones de clases. Los árboles de decisión pueden ser fácilmente convertidos en reglas de clasificación.” [Han Kamber]

- Hipótesis $f: X \rightarrow Y$
- Cada nodo interno evalúa un atributo x_i .
- Una bifurcación por cada posible valor de atributo $x_i = v$
- Se asigna a cada hoja una clase y .
- Para clasificar la entrada x : recorrer el árbol desde la raíz, hasta la hoja correspondiente.



Rattle 2018-Oct-29 20:12:03 mgualpa

Árbol de Decisión: Aplicaciones

Se recomienda el uso de árboles de decisión cuando se quiere:


- Aplicar un esquema de segmentación a un conjunto de datos que reflejan un grupo de potenciales clientes.
- Identificar posibles relaciones interactivas entre variables en una forma que le permita entender como el cambio de una variable puede afectar a otra.
- Proveer una representación visual de las relaciones entre variables en la forma de un árbol, que es una forma relativamente fácil de entender la naturaleza de los datos que residen en su base de datos.
- Simplificar la mezcla de atributos y categorías, manteniéndose solo con las necesarias para hacer predicciones.
- Explorar datos para identificar variables importantes en conjuntos de datos que pueden eventualmente ser usados como objetivos.

Árbol de Decisión: Caso de Estudio

“Patrones de morosidad para un producto crediticio usando la técnica de árbol de clasificación CART” [Salinas, 2005]

Variables: mora, edad, sexo, estado civil, carga familiar (personas dependientes), si posee teléfono particular, si posee teléfono laboral, si tiene “autovaluo”, si es aval de otro cliente, antigüedad laboral, si tiene renta fija o variable y la ubicación geográfica donde se aprobó el crédito.

Utilizando el algoritmo CART se detectaron patrones diferentes para los morosos y los no morosos, lo que ha permitido la automatización del proceso de crédito. Se obtuvo un 93,75% de clasificación correcta para los morosos y un 86,42% de clasificación correcta para los no morosos.




Árbol de Decisión: Algoritmo

“Un algoritmo de árbol de decisión analiza los datos y crea una serie de ramificaciones hasta que no puede hacer alguna relevante. El resultado final es una estructura de árbol ~~binario~~ donde los cortes en las ramas pueden ser seguidos a lo largo de un criterio específico para encontrar el resultado mas deseado.” [Seidman]

Teoría de Información: Incertidumbre

Cantidad de Información

Supongamos este conjunto de cartas:



Haremos extracciones sin reemplazo, asumiendo igual probabilidad de extracción para cada carta.

Se definen los sucesos:


$A = \{\text{sacar una carta negra (trébol)}\}$ donde $P(A) = 1/10$

$B = \{\text{sacar una carta roja (corazón)}\}$ donde $P(B) = 9/10$

Teoría de Información: Incertidumbre

Cantidad de Información

Supongamos este conjunto de cartas:




Haremos extracciones sin reemplazo, asumiendo igual probabilidad de extracción para cada carta.

Se definen los sucesos:

$A = \{\text{sacar una carta negra (trébol)}\}$ donde $P(A) = 1/10$

$B = \{\text{sacar una carta roja (corazón)}\}$ donde $P(B) = 9/10$

Al realizar la primer extracción, resulta:




¿Cuánta información aporta este suceso?

Teoría de Información: Incertidumbre

Cantidad de Información

Supongamos este conjunto de cartas:



$A = \{\text{sacar una carta negra (trébol)}\}$


$B = \{\text{sacar una carta roja (corazón)}\}$

- Al extraer una carta **roja**, este suceso B proporciona poca información, pues la incertidumbre en la próxima extracción varía muy poco: $P(A|B) = 1/9$ y $P(B|B) = 8/9$
- Si la carta hubiese sido **negra**, este suceso A proporciona mucha información, pues la incertidumbre sobre la próxima extracción desaparece: $P(A|A) = 0$ y $P(B|A) = 1$

Teoría de Información: Incertidumbre

La Teoría de la información [Shannon, 1948] permite cuantificar la cantidad de información y la entropía.

Supongamos este conjunto de cartas:




Hay una de entre cuatro posibilidades de sacar una carta negra (trébol).

Para el evento, se tiene una variable aleatoria con un grado de indeterminación $k=4$ (hay cuatro estados posibles), con una probabilidad $p = 1/k = 0,25$.

Teoría de Información: Incertidumbre

Cantidad de Información

Supongamos este conjunto de cartas:



Hay una de entre cuatro posibilidades de sacar una carta negra (trébol).

Para el evento, se tiene una variable aleatoria con un grado de indeterminación $k=4$ (hay cuatro estados posibles), con una probabilidad $p = 1/k = 0,25$.

Se define la cantidad de información c_i :

$$c_i = \log_2(k) = \log_2 [1 / (1/k)] = \log_2(1 / p) = \log_2(1) - \log_2(p) = - \log_2(p)$$

Entonces:

$$c_1 = \log_2(4) = - \log_2(0,25) = 2 \text{ bits}$$

Teoría de Información: Incertidumbre

Entropía

Cuantifica el nivel de desorganización o incertidumbre asociado a una variable aleatoria.

Se la define como el valor esperado de la cantidad de la información aportada por cada estado:

$$H(X) = - p(x_1) \log_2 p(x_1) - p(x_2) \log_2 p(x_2) \dots - p(x_k) \log_2 p(x_k)$$

$$H(X) = - \sum_i p(x_i) \log_2 p(x_i)$$

- Siempre está acotada en $H(X) \leq -\log_2(k)$
- Es máxima cuando $p_1 = p_2 = \dots = p_k = 1/k$
- Es 0 si algún $p_j = 1$ y los demás 0 (solo uno de los k estados puede aparecer).


Supongamos este conjunto de cartas:

En el ejemplo:

$$c_1 = -\log_2(p_1) = -\log_2(0,25) = 2 \text{ bits}$$

$$c_2 = -\log_2(p_2) = -\log_2(0,75) = 0,415 \text{ bits}$$

$$H(X) = -0,25 * \log_2(0,25) - 0,75 * \log_2(0,75) = 0,811$$



Teoría de Información: Incertidumbre


Entropía

- Ante resultados ciertos ($p = 0$ ó $p = 1$) la entropía es 0.
- Ante resultados inciertos, la entropía crece.
- Ante resultados igualmente probables, la entropía es máxima.

Lanzamiento de una moneda:

$$H(X) = - \sum_i p(x_i) \log_2 p(x_i)$$

$$H(X) = - 0,50 * \log_2(0,50) - 0,50 * \log_2(0,50) = 1$$




Teoría de Información: Incertidumbre

Cantidad de Información

¿A que juego prefieres jugar?

¿Adivinar el color de la carta o adivinar el lado de la moneda?



Teoría de Información: Incertidumbre

Entropía

Se propone un juego:

Dadas las seis cartas del conjunto, Pipo debe retirar una sola carta. Si la misma es un AS DE TRÉBOL, gana.

Sin ver la carta, debes adivinar si ganó o perdió.



X1: COLOR	X2: PAR O IMPAR	Y
R: ROJO	P: PAR	P: PERDIO
R: ROJO	I: IMPAR	P: PERDIO
R: ROJO	P: PAR	P: PERDIO
R: ROJO	I: IMPAR	P: PERDIO
N: NEGRO	P: PAR	P: PERDIO
N: NEGRO	I: IMPAR	G: GANO

Teoría de Información: Incertidumbre

Entropía

Se propone un juego:

Dadas las seis cartas del conjunto, Pipo debe retirar una sola carta. Si la misma es un AS DE TRÉBOL, gana.

Sin ver la carta, debes adivinar si ganó o perdió.

$$P(Y = P) = 5/6$$

$$P(Y = G) = 1/6$$

$$H(Y) = - 5/6 \log_2(5/6) - 1/6 \log_2(1/6) = 0,65$$



X1: COLOR	X2: PAR O IMPAR	Y
R: ROJO	P: PAR	P: PERDIO
R: ROJO	I: IMPAR	P: PERDIO
R: ROJO	P: PAR	P: PERDIO
R: ROJO	I: IMPAR	P: PERDIO
N: NEGRO	P: PAR	P: PERDIO
N: NEGRO	I: IMPAR	G: GANO

Teoría de Información: Incertidumbre

Entropía Condicional

El conocimiento de determinada información, podría afectar el nivel de incertidumbre que tenemos respecto al resultado de un evento.

Se define la entropía condicional de una variable aleatoria Y, condicionada por una variable aleatoria X como:

$$H(Y | X) = - \sum_{j=1}^v P(X = x_j) \sum_{i=1}^k P(Y = y_i | X = x_j) \log_2 P(Y = y_i | X = x_j)$$

Teoría de Información: Incertidumbre

Entropía Condicional

En nuestro Ejemplo, dado X_1 :

$$P(X_1 = R) = 4/6$$

$$P(X_1 = N) = 2/6$$

	Y = P	Y = G
$X_1 = R$	4	0
$X_1 = N$	1	1

$$H(Y | X) = - \sum_{j=1}^v P(X = x_j) \sum_{i=1}^k P(Y = y_i | X = x_j) \log_2 P(Y = y_i | X = x_j)$$

$$H(Y | X_1) = - 4/6 (1 \log_2 1 + 0 \log_2 0) - 2/6 (1/2 \log_2 1/2 + 1/2 \log_2 1/2) = 2/6$$



X1: COLOR	X2: PAR O IMPAR	Y
R: ROJO	P: PAR	P: PERDIO
R: ROJO	I: IMPAR	P: PERDIO
R: ROJO	P: PAR	P: PERDIO
R: ROJO	I: IMPAR	P: PERDIO
N: NEGRO	P: PAR	P: PERDIO
N: NEGRO	I: IMPAR	G: GANO

Teoría de Información: Incertidumbre

Ganancia de Información

Es el decremento en la entropía (es decir en la incertidumbre) dada determinada información.

$$IG(X) = H(Y) - H(Y | X)$$

Si $IG(X) > 0 \Rightarrow$ Se ha ganado información

En nuestro Ejemplo, dado X_1 :

$$H(Y) = - 5/6 \log_2(5/6) - 1/6 \log_2(1/6) = 0,65$$

$$H(Y | X_1) = - 4/6 (1 \log_2 1 + 0 \log_2 0) \\ - 2/6 (\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2}) = 2/6$$

$$IG(X_1) = H(Y) - H(Y | X_1) = 0,65 - 0,33 = \mathbf{0,32}$$



X1: COLOR	X2: PAR O IMPAR	Y
R: ROJO	P: PAR	P: PERDIO
R: ROJO	I: IMPAR	P: PERDIO
R: ROJO	P: PAR	P: PERDIO
R: ROJO	I: IMPAR	P: PERDIO
N: NEGRO	P: PAR	P: PERDIO
N: NEGRO	I: IMPAR	G: GANO

Índice de Gini (Impureza)

El índice de Gini mide la impureza de un nodo. Se calcula como:

$$Gini = 1 - \sum_k p_k^2$$

En el caso de clasificación binaria, la fórmula sería:

$$Gini = 1 - p_0^2 - p_1^2$$

Por ejemplo: Si tenemos en un nodo 5 muestras, 3 de la clase 0 y 2 de la clase 1, el índice de Gini será:

$$Gini = 1 - 0.6^2 - 0.4^2 = 0.48$$

El máximo se da cuando todas las clases tienen igual probabilidad. Ej:

$$Gini = 1 - 0,25^2 - 0,25^2 - 0,25^2 - 0,25^2 = 0,75$$

Árbol de Decisión: Algoritmo

En forma general, el algoritmo puede resumirse como:

- Inicial desde un árbol de decisión vacío.
- Crear ramas sobre el **mejor atributo (“feature”)**. Para hacerlo, debe identificarlo, usando por ejemplo la ganancia de información con el atributo seleccionado:

$$\arg \max_i IG(X_i) = \arg \max_i H(Y) - H(Y|X_i)$$

- Iterar hasta un criterio de corte.

Árbol de Decisión: Algoritmo ID3

```
Id3(Ejemplos, Atributo-objetivo, Atributos )
  Si todos los ejemplos son positivos devolver un nodo positivo
  Si todos los ejemplos son negativos devolver un nodo negativo
  Si Atributos está vacío devolver el voto mayoritario del valor del atributo objetivo en
  Ejemplos
  En otro caso
    Sea A Atributo el MEJOR de atributos
    Para cada v valor del atributo hacer
      Sea Ejemplos(v) el subconjunto de ejemplos cuyo valor de atributo A es v
      Si Ejemplos(v) esta vacío devolver un nodo con el voto mayoritario del
      Atributo objetivo de Ejemplos
    Sino Devolver Id3(Ejemplos(v), Atributo-objetivo, Atributos/{A})
```

Árbol de Decisión: Algoritmo ID3

Árbol de Decisión: Algoritmo ID3

Id3(Ejemplos, Atributo-objetivo, Atributos)

Si todos los ejemplos son positivos devolver un nodo positivo

Si todos los ejemplos son negativos devolver un nodo negativo

Si Atributos está vacío devolver el voto mayoritario del valor del atributo objetivo en Ejemplos

En otro caso

Sea A Atributo el MEJOR de atributos

Para cada v valor del atributo hacer

Sea Ejemplos(v) el subconjunto de ejemplos cuyo valor de atributo A es v

Si Ejemplos(v) esta vacío devolver un nodo con el voto mayoritario del Atributo objetivo de Ejemplos

Sino Devolver Id3(Ejemplos(v), Atributo-objetivo, Atributos/{A})

Ej.	Cielo	Temp.	Humedad	Viento	Jugar tenis
D1	Sol	Alta	Alta	Débil	-
D2	Sol	Alta	Alta	Fuerte	-
D3	Nubes	Alta	Alta	Débil	+
D4	Lluvia	Suave	Alta	Débil	+
D5	Lluvia	Baja	Normal	Débil	+
D6	Lluvia	Baja	Normal	Fuerte	-
D7	Nubes	Baja	Normal	Fuerte	+
D8	Sol	Suave	Alta	Débil	-
D9	Sol	Baja	Normal	Débil	+
D10	Lluvia	Suave	Normal	Débil	+
D11	Sol	Suave	Normal	Fuerte	+
D12	Nubes	Suave	Alta	Fuerte	+
D13	Nubes	Alta	Normal	Débil	+
D14	Lluvia	Suave	Alta	Fuerte	-

Árbol de Decisión: Algoritmo ID3

Árbol de Decisión: Algoritmo ID3

`Id3(Ejemplos, Atributo-objetivo, Atributos )`

Si todos los ejemplos son positivos devolver un nodo positivo

Si todos los ejemplos son negativos devolver un nodo negativo

Si Atributos está vacío devolver el voto mayoritario del valor del atributo objetivo en Ejemplos

En otro caso

Sea A Atributo el MEJOR de atributos

Para cada v valor del atributo hacer

Sea Ejemplos(v) el subconjunto de ejemplos cuyo valor de atributo A es v

Si Ejemplos(v) esta vacío devolver un nodo con el voto mayoritario del Atributo objetivo de Ejemplos

Sino Devolver `Id3(Ejemplos(v), Atributo-objetivo, Atributos/{A})`

Ej.	Cielo	Temp.	Humedad	Viento	Jugar tenis
D1	Sol	Alta	Alta	Débil	-
D2	Sol	Alta	Alta	Fuerte	-
D3	Nubes	Alta	Alta	Débil	+
D4	Lluvia	Suave	Alta	Débil	+
D5	Lluvia	Baja	Normal	Débil	+
D6	Lluvia	Baja	Normal	Fuerte	-
D7	Nubes	Baja	Normal	Fuerte	+
D8	Sol	Suave	Alta	Débil	-
D9	Sol	Baja	Normal	Débil	+
D10	Lluvia	Suave	Normal	Débil	+
D11	Sol	Suave	Normal	Fuerte	+
D12	Nubes	Suave	Alta	Fuerte	+
D13	Nubes	Alta	Normal	Débil	+
D14	Lluvia	Suave	Alta	Fuerte	-

Atributo	Valor	p	n	d	Entropía	%p	%n
Cielo	Sol	2	3	5	0,9710	0,4000	0,6000
	Nubes	4	0	4	#NUM!	1,0000	0,0000
	Lluvia	3	2	5	0,9710	0,6000	0,4000
Temp.	Alta	2	2	4	1,0000	0,5000	0,5000
	Baja	3	1	4	0,8113	0,7500	0,2500
Humedad	Suave	4	2	6	0,9183	0,6667	0,3333
	Alta	3	4	7	0,9852	0,4286	0,5714
Viento	Normal	6	1	7	0,5917	0,8571	0,1429
	Débil	6	2	8	0,8113	0,7500	0,2500
	Fuerte	3	3	6	1,0000	0,5000	0,5000

$$- \left(\frac{|p|}{|d|} \right) \log_2 \left(\frac{|p|}{|d|} \right) - \left(\frac{|n|}{|d|} \right) \log_2 \left(\frac{|n|}{|d|} \right)$$

Árbol de Decisión: Algoritmo ID3

Árbol de Decisión: Algoritmo ID3

Ej.	Cielo	Temp.	Humedad	Viento	Jugar tenis
D1	Sol	Alta	Alta	Débil	-
D2	Sol	Alta	Alta	Fuerte	-
D8	Sol	Suave	Alta	Débil	-
D9	Sol	Baja	Normal	Débil	+
D11	Sol	Suave	Normal	Fuerte	+

Ej.	Cielo	Temp.	Humedad	Viento	Jugar tenis
D3	Nubes	Alta	Alta	Débil	+
D7	Nubes	Baja	Normal	Fuerte	+
D12	Nubes	Suave	Alta	Fuerte	+
D13	Nubes	Alta	Normal	Débil	+

Ej.	Cielo	Temp.	Humedad	Viento	Jugar tenis
D4	Lluvia	Suave	Alta	Débil	+
D5	Lluvia	Baja	Normal	Débil	+
D6	Lluvia	Baja	Normal	Fuerte	-
D10	Lluvia	Suave	Normal	Débil	+
D14	Lluvia	Suave	Alta	Fuerte	-

$$-\left(\frac{|p|}{|d|}\right) \log_2 \left(\frac{|p|}{|d|}\right) - \left(\frac{|n|}{|d|}\right) \log_2 \left(\frac{|n|}{|d|}\right)$$


Atributo	Valor	p	n	d	Entropía	%p	%n
Temp.	Alta	0	2	2	#NUM!	0,0000	1,0000
	Suave	1	1	2	1,0000	0,5000	0,5000
	Baja	1	0	1	#NUM!	1,0000	0,0000
Humedad	Alta	0	3	3	#NUM!	0,0000	1,0000
	Normal	2	0	2	#NUM!	1,0000	0,0000
Viento	Débil	1	2	3	0,9183	0,3333	0,6667
	Fuerte	1	1	2	1,0000	0,5000	0,5000

Atributo	Valor	p	n	d	Entropía	%p	%n
Temp.	Alta	2	0	2	#NUM!	1,0000	0,0000
	Suave	1	0	1	#NUM!	1,0000	0,0000
	Baja	1	0	1	#NUM!	1,0000	0,0000
Humedad	Alta	2	0	2	#NUM!	1,0000	0,0000
	Normal	2	0	2	#NUM!	1,0000	0,0000
Viento	Débil	2	0	2	#NUM!	1,0000	0,0000
	Fuerte	2	0	2	#NUM!	1,0000	0,0000

Atributo	Valor	p	n	d	Entropía	%p	%n
Temp.	Alta	0	0	0	#DIV/0!	#DIV/0!	#DIV/0!
	Suave	2	1	3	0,9183	0,6667	0,3333
	Baja	1	1	2	1,0000	0,5000	0,5000
Humedad	Alta	1	1	2	1,0000	0,5000	0,5000
	Normal	2	1	3	0,9183	0,6667	0,3333
Viento	Débil	3	0	3	#NUM!	1,0000	0,0000
	Fuerte	0	2	2	#NUM!	0,0000	1,0000

Árbol de Decisión: Algoritmo ID3

Árbol de Decisión: Algoritmo ID3



Árbol de Decisión: Algoritmo ID3

Ejercicio: Suponga que solo tiene los atributos cielo y humedad. ¿cómo queda el árbol?

```

Id3(Ejemplos, Atributo-objetivo, Atributos )
  Si todos los ejemplos son positivos devolver un nodo positivo
  Si todos los ejemplos son negativos devolver un nodo negativo
  Si Atributos está vacío devolver el voto mayoritario del valor del atributo objetivo en
  Ejemplos

  En otro caso
    Sea A Atributo el MEJOR de atributos
    Para cada v valor del atributo hacer
      Sea Ejemplos(v) el subconjunto de ejemplos cuyo valor de atributo A es v
      Si Ejemplos(v) esta vacío devolver un nodo con el voto mayoritario del
      Atributo objetivo de Ejemplos
    Sino Devolver Id3(Ejemplos(v), Atributo-objetivo, Atributos/{A})
  
```

Ej.	Cielo	Temp.	Humedad	Viento	Jugar tenis
D1	Sol	Alta	Alta	Débil	-
D2	Sol	Alta	Alta	Fuerte	-
D3	Nubes	Alta	Alta	Débil	+
D4	Lluvia	Suave	Alta	Débil	+
D5	Lluvia	Baja	Normal	Débil	+
D6	Lluvia	Baja	Normal	Fuerte	-
D7	Nubes	Baja	Normal	Fuerte	+
D8	Sol	Suave	Alta	Débil	-
D9	Sol	Baja	Normal	Débil	+
D10	Lluvia	Suave	Normal	Débil	+
D11	Sol	Suave	Normal	Fuerte	+
D12	Nubes	Suave	Alta	Fuerte	+
D13	Nubes	Alta	Normal	Débil	+
D14	Lluvia	Suave	Alta	Fuerte	-

Atributo	Valor	p	n	d	Entropía	%p	%n
Cielo	Sol	2	3	5	0,9710	0,4000	0,6000
	Nubes	4	0	4	#NUM!	1,0000	0,0000
	Lluvia	3	2	5	0,9710	0,6000	0,4000
Temp.	Alta	2	2	4	1,0000	0,5000	0,5000
	Baja	3	1	4	0,8113	0,7500	0,2500
Humedad	Suave	4	2	6	0,9183	0,6667	0,3333
	Alta	3	4	7	0,9852	0,4286	0,5714
Viento	Normal	6	1	7	0,5917	0,8571	0,1429
	Débil	6	2	8	0,8113	0,7500	0,2500
	Fuerte	3	3	6	1,0000	0,5000	0,5000

$$- \left(\frac{|p|}{|d|} \right) \log_2 \left(\frac{|p|}{|d|} \right) - \left(\frac{|n|}{|d|} \right) \log_2 \left(\frac{|n|}{|d|} \right)$$

Árboles de Decisión: Sobreajuste (Overfitting)

- Los árboles de decisión estándar no tienen sesgo (bias) de aprendizaje.
 - El error del conjunto de entrenamiento siempre es 0 (sin un criterio de corte).
 - Mucha varianza.
 - Se debe introducir algún sesgo hacia árboles mas simples.
- Existen diferentes estrategias para simplificar árboles.
 - Establecer el nivel de profundidad.
 - Mínimo número de observaciones por hoja.
- Random Forests.

Árbol de Decisión: Familias de Algoritmos

- **Familia CART:** CART, Tree(S), etc. Su propósito inicial es la predicción estadística. Se basan en la realización de divisiones **binarias únicamente**, recurriendo a la validación cruzada y a la poda con el fin de determinar el tamaño correcto del árbol. Acepta como variable dependiente una del tipo **cuantitativa o nominal**. Las **variables predictoras pueden ser nominales u ordinales**, aunque las últimas versiones también admiten variables continuas.
- **Familia CLS:** CLS, ID3, C4.5, C5.0, etc. Detectan relaciones estadísticas complejas, siendo el número de ramas que puede **originar un número entre dos y el número de categorías** del predictor. Para determinar el tamaño del árbol utiliza tests de significación estadística (con ajustes de multiplicidad en las últimas versiones).

Árbol de Decisión: Familias de Algoritmos

- **Métodos de tipo discriminante:** FACT y QUEST. Su propósito inicial es solucionar problemas de los métodos exhaustivos. En concreto, tratan de **eliminar el denominado sesgo de selección** de la variable, que presentan métodos como CART y que consiste en la tendencia a seleccionar en primer lugar las variables con más categorías. QUEST logra eliminar este sesgo, sea la VD nominal u ordinal. En primer caso, diseñados para trabajar con **variables dependientes categóricas como continuas**. FACT divide a la población en tantos grupos como categorías tiene la variable seleccionada, QUEST establece **divisiones binarias**.
- **Combinaciones lineales:** OC1, Árboles SE, etc. Su propósito inicial es detectar relaciones lineales combinadas con el aprendizaje de conceptos. El número de ramas varía entre dos y el número de categorías del predictor.

Árbol de Decisión: Familias de Algoritmos

- **Modelos Híbridos:** IND, Knowledge Seeker, etc. Su propósito inicial es combinar métodos de otras familias. IND combina el CART y C4.5, así como métodos bayesianos y de codificación mínima. Knowledge Seeker combina CHAID y el ID3 con un novedoso ajuste de multiplicidad.

Se aclara además, que “los tres procedimientos arborescentes que actualmente gozan de una mayor aceptación tanto en los ámbitos teórico como aplicado son: los árboles CHAID (Kass, 1980), CART (Breiman et al., 1984) y QUEST (Loh y Shih, 1997)”.

¿Preguntas?

Muchas gracias.