

Ciencia de Datos



Unidad 4: Aprendizaje Supervisado

Tema: Clasificación Multiclase

Mgtr. Ing. Mariano Martín Gualpa (mgualpa@frc.utn.edu.ar)

Temario de la Clase



- El Problema de Clasificación.
- Problemas de Clasificación Multiclase.
- **Actividad Práctica**

El Problema de Clasificación

Problemática a Resolver


- La meta de la regresión logística es modelar relaciones entre un conjunto de variables predictoras y una variable objetivo **categorica** (target variable).
- ¿Desde donde? A partir de un conjunto suficientemente grande de pares $\mathbf{x}$ e y .
- Objetivos:
 - Determinar presencia o ausencia de relación entre variables predictoras y la variable dependiente.
 - Predecir la probabilidad de respuesta de cada valor posible, en función de la entrada.
 - Utilizar estas probabilidades para clasificar observaciones futuras.

Variables:

- Variables predictoras o covariables: $\mathbf{x} = (x_1, x_2, x_3, \dots, x_m)$.
- Variable objetivo categórica: y
 - Cantidad de Clases:
 - Clasificación Binaria: dos clases.
 - Clasificación Multiclase: mas de dos clases.
 - Tipo de Variable Categórica:
 - Variable Categórica Nominal.
 - Variable Categórica Ordinal.


Problemática a Resolver

- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función h .
 - Tal $\hat{y} = h(\mathbf{x})$ corresponda a la categoría correcta y con una alta probabilidad.




Problemática a Resolver

- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función h .
 - Tal $\hat{y} = h(\mathbf{x})$ corresponda a la categoría correcta y con una alta probabilidad.



Problemática a Resolver


- Datos: $(\mathbf{x}^{(1)}, y^{(1)})$, $(\mathbf{x}^{(2)}, y^{(2)})$, ..., $(\mathbf{x}^{(n)}, y^{(n)})$
- Meta: encontrar la mejor función h .
 - Tal $\hat{y} = h(\mathbf{x})$ corresponda a la categoría correcta y con una alta probabilidad.




Clasificación Multiclase

Clasificación Multiclase

Clasificación Binaria
(Binary Classification):




Clasificación Multiclase
(Multi-class Classification):



Clasificación Multiclase

Se obtiene la clasificación multiclase usando **one vs. all**:


- Se corta el problema en varios problemas separados de clasificación binaria (uno por cada clase de y).
- En el ejemplo se establecen tres h_w :
 - $h_w^{(1)}(\mathbf{x})$: Círculos (1) vs Cruces (0) y Cuadrados (0).
 - $h_w^{(2)}(\mathbf{x})$: Cruces (1) vs Círculos (0) y Cuadrados (0).
 - $h_w^{(3)}(\mathbf{x})$: Cuadrados (1) vs Círculos (0) y Cruces (0).



Clasificación Multiclase

Se obtiene la clasificación multiclase usando **one vs. all**:



- Se corta el problema en varios problemas separados de clasificación binaria (uno por cada clase de y).
- En el ejemplo se establecen tres h_w :
 - $h_w^{(1)}(\mathbf{x})$: Círculos (1) vs Cruces (0) y Cuadrados (0).
 - $h_w^{(2)}(\mathbf{x})$: Cruces (1) vs Círculos (0) y Cuadrados (0).
 - $h_w^{(3)}(\mathbf{x})$: Cuadrados (1) vs Círculos (0) y Cruces (0).



Clasificación Multiclase

Se obtiene la clasificación multiclase usando **one vs. all**:



- Se corta el problema en varios problemas separados de clasificación binaria (uno por cada clase de y).
- En el ejemplo se establecen tres h_w :
 - $h_w^{(1)}(\mathbf{x})$: Círculos (1) vs Cruces (0) y Cuadrados (0).
 - $h_w^{(2)}(\mathbf{x})$: Cruces (1) vs Círculos (0) y Cuadrados (0).
 - $h_w^{(3)}(\mathbf{x})$: Cuadrados (1) vs Círculos (0) y Cruces (0).



Clasificación Multiclase

Se obtiene la clasificación multiclase usando **one vs. all**:




- Se corta el problema en varios problemas separados de clasificación binaria (uno por cada clase de y).
- En el ejemplo se establecen tres h_w :
 - $h_w^{(1)}(\mathbf{x})$: Círculos (1) vs Cruces (0) y Cuadrados (0).
 - $h_w^{(2)}(\mathbf{x})$: Cruces (1) vs Círculos (0) y Cuadrados (0).
 - $h_w^{(3)}(\mathbf{x})$: Cuadrados (1) vs Círculos (0) y Cruces(0).



Clasificación Multiclase

Se obtiene la clasificación multiclase usando **one vs. all**:




- Se corta el problema en varios problemas separados de clasificación binaria (uno por cada clase de y).
- En el ejemplo se establecen tres h_w :
 - $h_w^{(1)}(\mathbf{x})$: Círculos (1) vs Cruces (0) y Cuadrados (0).
 - $h_w^{(2)}(\mathbf{x})$: Cruces (1) vs Círculos (0) y Cuadrados (0).
 - $h_w^{(3)}(\mathbf{x})$: Cuadrados (1) vs Círculos (0) y Cruces (0).



Clasificación Multiclase

Se obtiene la clasificación multiclase usando **one vs. all**:

- Se corta el problema en varios problemas separados de clasificación binaria (uno por cada clase de y).
- En el ejemplo se establecen tres h_w :
 - $h_w^{(1)}(\mathbf{x})$: Círculos (1) vs Cruces (0) y Cuadrados (0).
 - $h_w^{(2)}(\mathbf{x})$: Cruces (1) vs Círculos (0) y Cuadrados (0).
 - $h_w^{(3)}(\mathbf{x})$: Cuadrados (1) vs Círculos (0) y Cruces (0).



Se obtiene la clasificación multiclase usando **one vs. all**:

- Se corta el problema en varios problemas separados de clasificación binaria (uno por cada clase de y).
- En el ejemplo se establecen tres h_w :
 - $h_w^{(1)}(\mathbf{x})$: Círculos (1) vs Cruces (0) y Cuadrados (0).
 - $h_w^{(2)}(\mathbf{x})$: Cruces (1) vs Círculos (0) y Cuadrados (0).
 - $h_w^{(3)}(\mathbf{x})$: Cuadrados (1) vs Círculos (0) y Cruces(0).




Para utilizar:

- Entrenar los clasificadores de regresión logística $h_w^{(i)}(\mathbf{x})$ para cada clase i , buscando predecir la probabilidad de $y = i$
- Para cada nueva $\mathbf{x}$, hacer la predicción y asignar la clase i que maximiza la probabilidad de que $h_w^{(i)}(\mathbf{x}) = 1$

Clasificación Multiclase

Problemas usando **one vs. all**:


Esta descomposición no siempre funciona.



Clasificación Multiclase

Problemas usando **one vs. all**:


Esta descomposición no siempre funciona.



Clasificación Multiclase

Clasificación All-vs-All (a veces One-vs-One)

Asumiendo que cada par de clases es separable, entonces:



Entrenamiento:

- Dado un conjunto de datos $D = \{x^{(i)}, y^{(i)}\}$, donde $x^{(i)} \in \mathbb{R}^m$, $y \in \{1, 2, \dots, k\}$
- Por cada par de etiquetas (j, k) , crear un clasificador binario donde:
 - Los ejemplos positivos son todos los ejemplos con etiqueta j .
 - Los ejemplos negativos son todos los ejemplos con etiqueta k .
- Entrenar $\binom{k}{2} = \frac{k(k-1)}{2}$ clasificadores que separen cada par de etiquetas.

Predicción:

- Por cada etiqueta, tomar $k-1$ votos.
- Combinar los votos:
 - Seleccionar la etiqueta con mayor cantidad de votos.
 - Organizar torneos entre las etiquetas: iniciar con $k/2$ pares y continuar con los ganadores.

Clasificación All-vs-All (a veces One-vs-One)


Problemas:

- Muchos vectores de pesos para entrenar y almacenar. $O(K^2)$.
- Por algunos pares de etiquetas, el tamaño del conjunto de entrenamiento podría ser muy pequeño $\Rightarrow$ overfitting.
- Problemas de posible inestabilidad con la predicción:
 - ¿Secuencia del torneo?
 - ¿Empate en votos?

Otros enfoques para clasificación multiclase:

- Error Correcting Output Codes (ECOC)
- Específicos del Modelo o Algoritmo: por ejemplo regresión logística.

¿Preguntas?



¡Muchas gracias!

