

Ciencia de Datos



Unidad 4: Aprendizaje No Supervisado

Temas: Reducción de Dimensionalidad, Clustering

Mgtr. Ing. Mariano Martín Gualpa (mgualpa@frc.utn.edu.ar)

Temario de la Clase



- Aprendizaje No Supervisado.
- Reducción de Dimensionalidad.
- Análisis de Componentes Principales (PCA).
- Agrupamiento.
- Agrupamiento Jerárquico.
- Agrupamiento No Jerárquico.
- Agrupamiento: Problemas Prácticos.
- Validación de los Grupos.
- Otras Consideraciones.
- Interpretación de Resultados.

Aprendizaje No Supervisado

Aprendizaje No Supervisado

Tipos de Aprendizaje:

- Aprendizaje Supervisado.
- Aprendizaje No Supervisado.
- Aprendizaje Semi-Supervisado.
- Aprendizaje por Refuerzo.

Objetivos:

- **Reducción de Dimensionalidad**
- **Agrupamiento (Clustering)**
- Generación de Jerarquías
- Sistemas de Recomendación
- Reglas de Asociación
- Visualización
- Detección de Anomalías.

Reducción de Dimensionalidad

Reducción de Dimensionalidad

Se han estudiado diferentes formas de controlar la varianza:

- Usando un subconjunto de las variables originales.
- Reduciendo sus coeficientes a cero.

Ahora estudiaremos otra aproximación, a partir de transformar los predictores.

En definitiva:

A partir de los predictores originales $X_1, X_2, \dots, X_p$, se busca una representación basada en los predictores $Z_1, Z_2, \dots, Z_M$ donde $M < p$

X1	X2	X3	...	Xp
...				

Z1	Z2	...	ZM
...			

Reducción de Dimensionalidad

En los modelos estudiados, utilizamos los predictores originales $X_1, X_2, \dots, X_p$. Sean $Z_1, Z_2, \dots, Z_M$ representantes de $M < p$ combinaciones lineales de nuestros p predictores originales. Es decir:

$$Z_m = \sum_{j=1}^p \phi_{jm} X_j$$

X1	X2	X3	...	Xp

Z1	Z2	...	ZM

Para algunas constantes $\phi_{1m}, \phi_{2m}, \dots, \phi_{pm}$, $m = 1, \dots, M$. Usando mínimos cuadrados, podemos ajustar el modelo de regresión lineal:

$$y_i = \theta_0 + \sum_{m=1}^M \theta_m z_{im} + \epsilon_i, \quad i = 1, \dots, n,$$

Si las constantes son elegidas sabiamente, a menudo pueden mejorar la regresión de mínimos cuadrados.

$$\sum_{m=1}^M \theta_m z_{im} = \sum_{m=1}^M \theta_m \sum_{j=1}^p \phi_{jm} x_{ij} = \sum_{j=1}^p \sum_{m=1}^M \theta_m \phi_{jm} x_{ij} = \sum_{j=1}^p \beta_j x_{ij} \quad \text{donde} \quad \beta_j = \sum_{m=1}^M \theta_m \phi_{jm}$$

Reducción de Dimensionalidad

En los modelos estudiados, utilizamos los predictores originales $X_1, X_2, \dots, X_p$. Sean $Z_1, Z_2, \dots, Z_M$ representantes de $M < p$ combinaciones lineales de nuestros p predictores originales. Es decir:

$$Z_m = \sum_{j=1}^p \phi_{jm} X_j$$

X1	X2	X3	...	Xp

Z1	Z2	...	ZM

Para algunas constantes $\phi_{1m}, \phi_{2m}, \dots, \phi_{pm}$, $m = 1, \dots, M$. Usando mínimos cuadrados, podemos ajustar el modelo de regresión lineal:

$$y_i = \theta_0 + \sum_{m=1}^M \theta_m z_{im} + \epsilon_i, \quad i = 1, \dots, n,$$

Si las constantes son elegidas sabiamente, a menudo pueden mejorar la regresión de mínimos cuadrados.

$$\sum_{m=1}^M \theta_m z_{im} = \sum_{m=1}^M \theta_m \sum_{j=1}^p \phi_{jm} x_{ij} = \sum_{j=1}^p \sum_{m=1}^M \theta_m \phi_{jm} x_{ij} = \sum_{j=1}^p \beta_j x_{ij} \quad \text{donde} \quad \beta_j = \sum_{m=1}^M \theta_m \phi_{jm}$$

Reducción de Dimensionalidad

$$\sum_{m=1}^M \theta_m z_{im} = \sum_{m=1}^M \theta_m \sum_{j=1}^p \phi_{jm} x_{ij} = \sum_{j=1}^p \sum_{m=1}^M \theta_m \phi_{jm} x_{ij} = \sum_{j=1}^p \beta_j x_{ij} \quad \text{donde} \quad \beta_j = \sum_{m=1}^M \theta_m \phi_{jm}$$

- Puede ser tratado como un caso especial del modelo de regresión lineal original ya estudiado.
- La reducción de dimensión sirve para restringir los coeficientes estimados β .
- Esta restricción sobre la forma de los coeficientes, tiene el potencial de sesgar las estimaciones.
- Sin embargo, cuando p es grande en relación a n , seleccionar un valor de $M \ll p$ puede reducir significativamente la varianza de los coeficientes ajustados.
- Si $M = p$, y todos los Z_m son linealmente independientes, no hay reducción y el resultado es equivalente a usar los p predictores originales.


p dims					M dims				
x1	x2	x3	...	x _p	z1	z2	...	z _M	

Todos los métodos de reducción de dimensionalidad trabajan en dos pasos:


1. Obtener los predictores transformados $Z_1, Z_2 \dots Z_M$.
2. Ajustar el modelo con esos M predictores.

No obstante, existen diferentes formas de obtener dichos predictores.



Análisis de Componentes Principales (PCA)




Análisis de Componentes Principales (PCA)




Análisis de Componentes Principales (PCA)



Análisis de Componentes Principales (PCA)



Análisis de Componentes Principales (PCA)



Análisis de Componentes Principales (PCA)

La primer componente principal de un conjunto $X_1, X_2, \dots, X_p$ es la combinación lineal normalizada (normalized linear combination):

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \dots + \phi_{p1}X_p$$

X_1	X_2	X_3	...	X_p

Z_1	Z_2	...	Z_M

que tiene la varianza más grande. Por normalizada nos referimos a: $\sum_{j=1}^p \phi_{j1}^2 = 1$

$$\sum_{j=1}^p \phi_{j1}^2 = 1$$

Esta restricción normaliza el vector de loadings, para que siempre tenga módulo 1, pues solo nos interesa su dirección (genera una esfera de un espacio multidim.). Puede demostrarse que sin esta restricción, los loadings crecerían indefinidamente al maximizar la varianza.

Análisis de Componentes Principales (PCA)

La primer componente principal de un conjunto $X_1, X_2, \dots, X_p$ es la combinación lineal normalizada (normalized linear combination):

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \dots + \phi_{p1}X_p$$

X1	X2	X3	...	Xp

Z1	Z2	...	ZM

que tiene la varianza más grande. Por normalizada nos referimos a: $\sum_{j=1}^p \phi_{j1}^2 = 1$

Los elementos $\phi_{11}, \dots, \phi_{p1}$ son llamados “**loadings**” de la primer componente principal, formando el “loading vector” $\Phi_1 = (\phi_{11}, \phi_{21}, \dots, \phi_{p1})^T$.

La restricción de que sumen 1 ya que de establecerlos grandes en valor absoluto podrían resultar en una varianza arbitrariamente grande.

Como solo estamos interesados en la varianza, asumimos que cada una de las variables en $\mathbf{X}$ está centrada en la media cero.

Cada valor de la combinación lineal se calcula como:

$$z_{i1} = \phi_{11}x_{i1} + \phi_{21}x_{i2} + \dots + \phi_{p1}x_{ip}$$

X1	X2	X3	...	Xp

Z1	Z2	...	ZM

Que tiene la mayor varianza de las muestras, sujetas a la restricción $\sum_{j=1}^p \phi_{j1}^2 = 1$

Análisis de Componentes Principales (PCA)

La primer componente principal de un conjunto $X_1, X_2, \dots, X_p$ es la combinación lineal normalizada (normalized linear combination):

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \dots + \phi_{p1}X_p$$

Que tiene la varianza más grande. Por normalizada nos referimos a: $\sum_{j=1}^p \phi_{j1}^2 = 1$

$$z_{i1} = \phi_{11}x_{i1} + \phi_{21}x_{i2} + \dots + \phi_{p1}x_{ip}$$

En otras palabras, el vector de loadings de la primer componente principal resuelve el problema de optimización:

$$\underset{\phi_1}{\text{maximize}} \{ \text{Var}(\overbrace{X\phi_1}^{Z_1}) \} \text{ subject to } \|\phi_1\| = 1$$

Que podemos expresar también como:

$$\underset{\phi_{11}, \dots, \phi_{p1}}{\text{maximize}} \left\{ \frac{1}{n} \sum_{i=1}^n \left(\sum_{j=1}^p \phi_{j1} x_{ij} \right)^2 \right\} \text{ subject to } \sum_{j=1}^p \phi_{j1}^2 = 1$$

Análisis de Componentes Principales (PCA)

Partiendo del modelo:

$$\text{maximize}_{\phi_1} \{Var(X\phi_1)\} \text{ subject to } \|\phi_1\|^2 = 1$$

Puede demostrarse que:

$$Var(X\phi_1) = \phi_1^T S \phi_1$$

Donde S es la matriz de covarianza muestral centrada de X.

En definitiva, el problema es:

$$\text{maximize}_{\phi_1} \{\phi_1^T S \phi_1\} \text{ subject to } \|\phi_1\|^2 = 1$$

Cuando se resuelve por multiplicadores de Lagrange:

$$L(\phi, \lambda) = \phi^T S \phi - \lambda (\phi^T \phi - 1)$$

Derivando respecto a ϕ resulta el mismo problema que define cual es el autovector.

$$\nabla_{\phi} L = 2 S \phi - 2 \lambda \phi = 0 \Rightarrow S \phi = \lambda \phi$$

Entonces:

- Los vectores ϕ_i que maximizan la varianza son autovectores de la matriz de covarianza S.
- Los autovalores λ_i indican cuanta varianza explica cada componente.
- Como S es simétrica, entonces sus autovectores son ortogonales.

Análisis de Componentes Principales (PCA)

Una componente principal puede ser definida como una combinación lineal de las observaciones, óptimamente ponderadas.


Propiedades:

- Los componentes principales son combinaciones lineales de las variables originales.
- El vector de pesos en esta combinación es el autovector encontrado que a su vez satisface el principio de mínimos cuadrados.
- Los componentes principales son ortogonales.
- La variación de las Componentes Principales disminuye a medida que pasamos de la 1ra a la última (es decir, disminuye su importancia).

Las componentes principales menos importantes son a veces útiles en regresión, detección de outliers, etc. Eliminarlas, puede ayudar a eliminar ruido.

Análisis de Componentes Principales (PCA)

¿Cuanto de la varianza en los datos no está contenida en las primeras componentes principales?



Se busca conocer la proporción de la varianza explicada (PVE) de cada componente principal.

Análisis de Componentes Principales (PCA)

El total de la varianza del dataset (asumiendo variables centradas con media 0) se define como:


$$\sum_{j=1}^p \text{Var}(X_j) = \sum_{j=1}^p \frac{1}{n} \sum_{i=1}^n x_{ij}^2$$

La varianza explicada por la componente principal m-ésima:

$$\frac{1}{n} \sum_{i=1}^n z_{im}^2 = \frac{1}{n} \sum_{i=1}^n \left(\sum_{j=1}^p \phi_{jm} x_{ij} \right)^2$$

Entonces, la proporción de varianza explicada ("proportion of variance explained", PVE) es:

$$\frac{\sum_{i=1}^n \left(\sum_{j=1}^p \phi_{jm} x_{ij} \right)^2}{\sum_{j=1}^p \sum_{i=1}^n x_{ij}^2}$$



Agrupamiento (Clustering)

Agrupamiento (Clustering)

Objetivos:

- Dados ejemplos sin etiquetar, agruparlos siguiendo algún criterio predefinido:
 - Aprendizaje Paramétrico: parámetros asumidos, por ejemplo que los datos siguen una función de densidad de probabilidad específica.
 - Aprendizaje No Paramétrico: alguna medida de distancia.

Agrupamiento (Clustering)

Los algoritmos de clustering no pueden diferenciar entre variables relevantes e irrelevantes. Es importante elegir cuidadosamente las variables basado en el algoritmo que iniciará la identificación de patrones/grupos. Es muy importante porque los clusters pueden ser muy dependientes de las variables incluidas.

Un buen algoritmo de clustering puede ser evaluado en base a dos objetivos primarios:

- Alta similaridad dentro de cada grupo (intra-class).
- Baja similaridad entre grupos (inter-class).

Agrupamiento (Clustering)

Elementos críticos:

- ¿cuántos grupos tiene el conjunto?
- ¿cómo se determina el grupo al que pertenece una instancia?

Agrupamiento (Clustering)

		$\mathbf{X}_1$	...	$\mathbf{X}_j$	...	$\mathbf{X}_n$	$\mathbf{C}$
1	$(\mathbf{x}^{(1)}, \mathbf{C}^{(1)})$	x_{11}	...	x_{1j}	...	x_{1n}	$\mathbf{C}^{(1)}$
...	...	...	...	...	...	...	
i	$(\mathbf{x}^{(i)}, \mathbf{C}^{(i)})$	x_{i1}	...	x_{ij}	...	x_{in}	$\mathbf{C}^{(i)}$
...	...	...	...	...	...	...	
N	$(\mathbf{x}^{(N)}, \mathbf{C}^{(N)})$	x_{N1}	...	x_{Nj}	...	x_{Nn}	$\mathbf{C}^{(N)}$
N + 1	$\mathbf{X}^{(N+1)}$	$x_{N+1,1}$	...	$x_{N+1,j}$	...	$x_{N+1,n}$	???

En agrupamiento, esta fase es opcional.

En agrupamiento, no tenemos etiquetas.

Agrupamiento (Clustering)

		x_1	...	x_j	...	x_n	c
1	$(\mathbf{x}^{(1)}, C^{(1)})$	x_{11}	...	x_{1j}	...	x_{1n}	$C^{(1)}$
...	...	...	...	...	...	...	
i	$(\mathbf{x}^{(i)}, C^{(i)})$	x_{i1}	...	x_{ij}	...	x_{in}	$C^{(i)}$
...	...	...	...	...	...	...	
N	$(\mathbf{x}^{(N)}, C^{(N)})$	x_{N1}	...	x_{Nj}	...	x_{Nn}	$C^{(N)}$
N + 1	$\mathbf{X}^{(N+1)}$	$x_{N+1,1}$	...	$x_{N+1,j}$	...	$x_{N+1,n}$	???

- Encontrar agrupamientos naturales en un conjunto de datos no etiquetados.
- Homogeneidad dentro de las clases y heterogeneidad entre las distintas clases.
- A veces, se busca predecir la etiqueta de un ejemplo nuevo, con los grupos ya definidos.

Agrupamiento (Clustering)

Ejemplos:

Marketing: diferentes grupos de clientes.


Seguros: identificar características de los grupos con alto costo promedio.

Planeamiento Gubernamental: identificar grupos de familias para esquemas sociales, en base a atributos como tamaño, ingresos, etc.

Taxonomías: los biólogos usan clustering para crear árboles de taxonomías de grupos y subgrupos de especies similares.



Agrupamiento (Clustering)

¿qué consideramos un grupo?
es una definición que puede ser ambigua






Agrupamiento (Clustering)

¿qué consideramos un grupo?
es una definición que puede ser ambigua







Agrupamiento (Clustering)

¿qué consideramos un grupo?
es una definición que puede ser ambigua



Agrupamiento (Clustering)

¿qué consideramos un grupo?
es una definición que puede ser ambigua



Tipos de Agrupamiento:

- Jerárquico: busca agrupar los datos de forma natural mediante una estructura de árbol.
- No Jerárquico:
 - Particional: forma particiones naturales de los dato en un número de grupos (normalmente parámetro). Similar al problema de clasificación, pero no se tienen las etiquetas. Normalmente basado en técnicas de optimización.
 - Probabilísticas: suele asumir densidades condicionales para los clusters (por ejemplo Gaussianas) y estima los parámetros de las mismas.

Otra clasificación de tipos de agrupamiento:

- Connectivity Models: la medida es la distancia de conectividad entre observaciones (ej: jerárquicos).
- Centroids Models: la medida es la distancia desde el valor de media de cada observación/cluster (ej: kmeans, kmedoids).
- Distribution Models: la medida es la significancia de la distribución estadística de variables en el dataset (ej: algoritmos de maximización de expectativa).
- Density models: la medida es la densidad en el espacio de los datos (ej: DBSCAN).

Agrupamiento (Clustering)

Pasos del análisis de cluster:

- Seleccionar una medida de similaridad.
- Elegir la técnica a usar (jerárquica, no jerárquica).
- Elegir el método o algoritmo dentro de la técnica.
- Si corresponde, decidir cuantos clusters hacer.
- Interpretar los clusters formados (deducir las propiedades que dividen).

Agrupamiento (Clustering)

Interpretación Geométrica


Formar grupos homogéneos de las observaciones $\mathbf{x}^{(i)}$, respecto a las variables.

Similares, homogéneos: depende del objetivo de estudio. Se busca cohesión interna, aislamiento externo.





Agrupamiento Jerárquico



Agrupamiento Jerárquico





Agrupamiento Jerárquico




Agrupamiento Jerárquico



Agrupamiento Jerárquico



Agrupamiento Jerárquico



Algoritmo Jerárquico:

1. Empezar con n observaciones y una métrica (como distancia Euclídea) de todas las $\binom{n}{2} = \frac{n(n-1)}{2}$ disimilaridades por pares. Tratar a cada observaciones como su propio cluster.
2. Para i en $(n, n-1, \dots, 2)$:
 - a) Examinar todas las diferencias entre grupos por pares e identificar el par que es menos diferente (es decir, más similar). Fusionar estos grupos. La diferencia entre estos grupos indica la altura en el dendograma a la que debe colocarse la fusión.
 - b) Calcular las nuevas diferencias por pares entre los $i - 1$ grupos restantes.


Tipos de Enlace:

Linkage	Descripción
Complete	Máxima disimilitud entre clusters. Calcular todas las disimilitudes de a pares entre las observaciones del cluster A y las del B, y registrar la mayor de todas.
Single	Mínima disimilitud entre clusters. Calcular todas las disimilitudes entre las observaciones del cluster A y las del cluster B, y registrar la mas pequeña de todas.
Average	Disimilitud media entre clusters. Calcular todos los pares de disimilitudes entre las observaciones en el cluster y las del B, y registrar el promedio de las mismas.
Centroid	Disimilitud entre el centroide para el cluster A (un vector de medias de longitud p) y el centroide del clusted B.

Agrupamiento Jerárquico

Complete Linkage:


- Máxima disimilitud entre clusters. Calcular todas las disimilitudes de a pares entre las observaciones del cluster A y las del B, y registrar la mayor de todas.



Agrupamiento Jerárquico

Single Linkage:


- Mínima disimilitud entre clusters. Calcular todas las disimilitudes entre las observaciones del cluster A y las del cluster B, y registrar la más pequeña de todas.
- Puede dar como resultado clusters extendidos y finales en los que las observaciones individuales se fusionan una a la vez.



Agrupamiento Jerárquico


Average Linkage:

- Disimilitud media entre clusters. Calcular todos los pares de disimilitudes entre las observaciones en el cluster A y las del B, y registrar el promedio de las mismas.




Centroid Linkage:

- Disimilitud entre el centroide para el cluster A (un vector de medias de longitud p) y el centroide del cluster B.



Agrupamiento Jerárquico



Agrupamiento No Jerárquico

Agrupamiento No Jerárquico: K-Means

El objetivo del algoritmo K-Means es dividir M puntos en N dimensiones en K grupos de modo que se minimice la suma de cuadrados dentro del grupo. No es práctico exigir que la solución tenga una suma mínima de cuadrados contra todas las particiones, excepto cuando M, N son pequeños y K=2. En cambio, buscamos “óptimos locales”, una solución tal que no haya movimiento de un punto de un grupo a otro que reduzca dicha suma de cuadrados entre clusters.

Donde suma de cuadrados dentro del cluster (within cluster sum of squares, WCSS) es la suma de los cuadrados de las distancias de cada observación en un cluster a su centroide.

$$WCSS = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \mu_i\|^2$$

Algoritmo k-means


En su forma más sencilla, consta de dos pasos:

- Asignación: asignar cada observación al cluster que da la menor suma de cuadrados dentro del cluster (Within Cluster Sum o Squares, WCSS).
- Actualización: Actualizar el centroide por tomar la media de todas las observaciones dentro del cluster.

Se ejecutan estos pasos hasta que las asignaciones en dos iteraciones consecutivas no cambian, significando que se ha encontrado un óptimo local o global (no siempre garantizado)


Agrupamiento No Jerárquico: K-Means

▪



Agrupamiento No Jerárquico: K-Means

Curva de codo (elbow)



K-Means

Propiedades a satisfacer:

1. Cada observación pertenece al menos a uno de los K clusters.

$$C_1 \cup C_2 \cup \dots \cup C_K = \{1, \dots, n\}$$

2. Los clusters no están solapados: ninguna observación pertenece a más de un cluster.

$$C_k \cap C_{k'} = \emptyset \text{ for all } k \neq k'.$$

Agrupamiento No Jerárquico: K-Means

K-Means

Se busca resolver el problema:

$$\underset{C_1, \dots, C_K}{\text{minimize}} \left\{ \sum_{k=1}^K W(C_k) \right\}$$

Donde:

$$W(C_k) = \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2$$

Es decir:


$$\underset{C_1, \dots, C_K}{\text{minimize}} \left\{ \sum_{k=1}^K \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2 \right\}$$

Agrupamiento No Jerárquico: K-Means

Algoritmo K-Means:

1. Aleatoriamente asignar un número, desde 1 a K, para cada una de las observaciones. Esto sirve como una asignación inicial de cluster para las observaciones.
2. Iterar hasta que la asignación de clusters pare de cambiar:
 - a) Por cada uno de los K clusters, calcular el centroide del cluster (cluster centroid). El centroide del k-ésimo cluster es el vector de las medias de las p variables para las observaciones dentro de dicho cluster.
 - b) Asignar cada observación al cluster cuyo centroide sea mas cercano (donde cercano se define usando la distancia Euclídea).

Agrupamiento No Jerárquico: K-Means



Agrupamiento No Jerárquico: K-Means


Problema:

Es muy sensible a la
asignación aleatoria inicial.



Agrupamiento No Jerárquico: K-Means

Otra implementación:



Agrupamiento No Jerárquico: K-Means

$K = 2$



$K = 3$



$K = 10$



Original image



Agrupamiento No Jerárquico: K-Medoids

K-Medoids: Algoritmo PAM (Partitioning Around Medoids):

1. Inicialización: seleccionar k de los n puntos como medoids para minimizar el costo.
2. Asociar cada punto al medoid más cercano.
3. Mientras el costo de la configuración disminuya:
 - a. Para cada medoid m y para cada no medoid o :
 - I. Intercambiar m y o , calcular el costo del cambio (suma de los puntos a sus medoids).
 - II. Si el costo del cambio es el actualmente mejor, recordar esta combinación de m y o .
 - b. Realizar el mejor intercambio de m_{best} y o_{best} si este decrementa la función de costo. Si no, termina el algoritmo.

Considerar:

$$\text{costo}(x, c) = \sum_{k=1}^d |x_i - c_i|$$

donde x es cualquier objeto, c es el medoid, y d es la dimensión del objeto


Agrupamiento Basado en Densidad: DBSCAN

- Density-based spartial clustering of application with noise (DBSCAN).
- Propuesto por Martin Ester, Hans-Peker Kriegel, Jörg Sander y Xiaowei Xi, en 1996.
- Trabaja sobre una aproximación paramétrica. Los dos parámetros son:
 - ϵ : El radio de vecinos alrededor del punto de dato p .
 - **minPts**: El mínimo número de puntos de dato que queremos en un vecindario para definir un cluster.

Agrupamiento No Jerárquico: DBScan

El algoritmo divide los puntos de dato en tres tipos de punto:


- **Core points:** p es core point si al menos minPts están dentro de una distancia ε (incluyendo a p).
- **Border points:** q es border point de p si hay una ruta $p_1, \dots, p_n$ con $p_1 = p$ y $p_n = q$, donde cada p_{i+1} es accesible desde p_i (todos los puntos sobre la ruta deben ser core points, con la posible excepción de q).
- **Outliers:** todos los puntos no accesibles desde otro punto son outliers.



Agrupamiento No Jerárquico: DBScan

Algoritmo DBSCAN:

1. Tomar un punto aleatorio que no esté asignado a un cluster y calcular su vecindario. Si en el mismo, este punto tiene minPts , entonces hacer un cluster alrededor de él. Si no, marcarlo como outlier.
2. Una vez que encontró todos los core points, empezar a expandir hasta incluir border points.
3. Repetir estos pasos hasta que todos los puntos sean asignados a un cluster o se los considere outliers.



Agrupamiento No Jerárquico: DBScan

```
library(dbscan)
Warning: package 'dbscan' was built under R version 3.2.5
cluster_dbscan <- dbscan(Data_House_Worth[,2:3],eps=0.8,minPts =10)
cluster_dbscan
DBSCAN clustering for 316 objects.
Parameters: eps = 0.8, minPts = 10
The clustering contains 5 cluster(s) and 226 noise points.

  0  1  2  3  4  5
226 10 25 24 15 16

Available fields: cluster, eps, minPts
#Display the hull plot
hullplot(Data_House_Worth[,2:3],cluster_dbscan$cluster)
```

Agrupamiento: Evaluación Interna

Agrupamiento: Evaluación Interna

El coeficiente silhouette contrasta la distancia promedio a elementos en el mismo cluster con la distancia promedio a los elementos en otros clusters. Los objetos con un alto valor de silhouette son considerados bien agrupados, los objetos con valor bajo, podrían ser outliers.

1. Definimos $a(i)$ la media de la distancia entre i y todos los demás puntos del cluster en el que está i :

$$a(i) = \frac{1}{|C_i| - 1} \sum_{j \in C_i, i \neq j} d(i, j)$$

2. Además, definimos $b(i)$ como la media de la distancia entre i a todos los puntos fuera del cluster de i .

$$b(i) = \min_{k \neq i} \frac{1}{|C_k|} \sum_{j \in C_k} d(i, j)$$

1. Definimos $a(i)$ la media de la distancia entre i y todos los demás puntos del cluster en el que está i :

$$a(i) = \frac{1}{|C_i| - 1} \sum_{j \in C_i, i \neq j} d(i, j)$$


2. Además, definimos $b(i)$ como la media de la distancia entre i a todos los puntos fuera del cluster de i .

$$b(i) = \min_{k \neq i} \frac{1}{|C_k|} \sum_{j \in C_k} d(i, j)$$

3. Definimos entonces el coeficiente $s(i)$ como:

$$\left\{ \begin{array}{ll} s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} & \text{si } |C_i| > 1 \\ s(i) = 0 & \text{si } |C_i| = 1 \end{array} \right.$$

Agrupamiento: Evaluación Interna



Agrupamiento: Problemas Prácticos

Agrupamiento: Problemas Prácticos

Decisiones importantes:

- ¿Estandarizar el dataset antes? Es muy importante!
- En el caso de clustering jerárquico:
 - ¿que medida de disimilitud debería usarse?
 - ¿qué tipo de linkage debería usarse?
 - ¿dónde debería cortarse el dendograma para obtener los clusters?
- En el caso de clustering particional (K-Means, etc):
 - ¿cuantos clusters deberíamos buscar en los datos?

Estas decisiones tienen impactos importantes en los resultados.
En la práctica, se prueban diferentes opciones, y se toma la solución más útil o interpretable.
No hay una única respuesta correcta (cada solución expone algún aspecto interesante a considerar sobre los datos).

Validación de Clusters Obtenidos:

- A veces buscamos obtener subgrupos verdaderamente representativos en los datos.
- Otras veces, buscamos detectar ruido.
- Existen técnicas para asignar un p-value a un cluster.
- No hay consenso sobre una única mejor aproximación.
- Conocimiento de dominio.
- Análisis exploratorio.

¿Preguntas?

¡Muchas Gracias!